

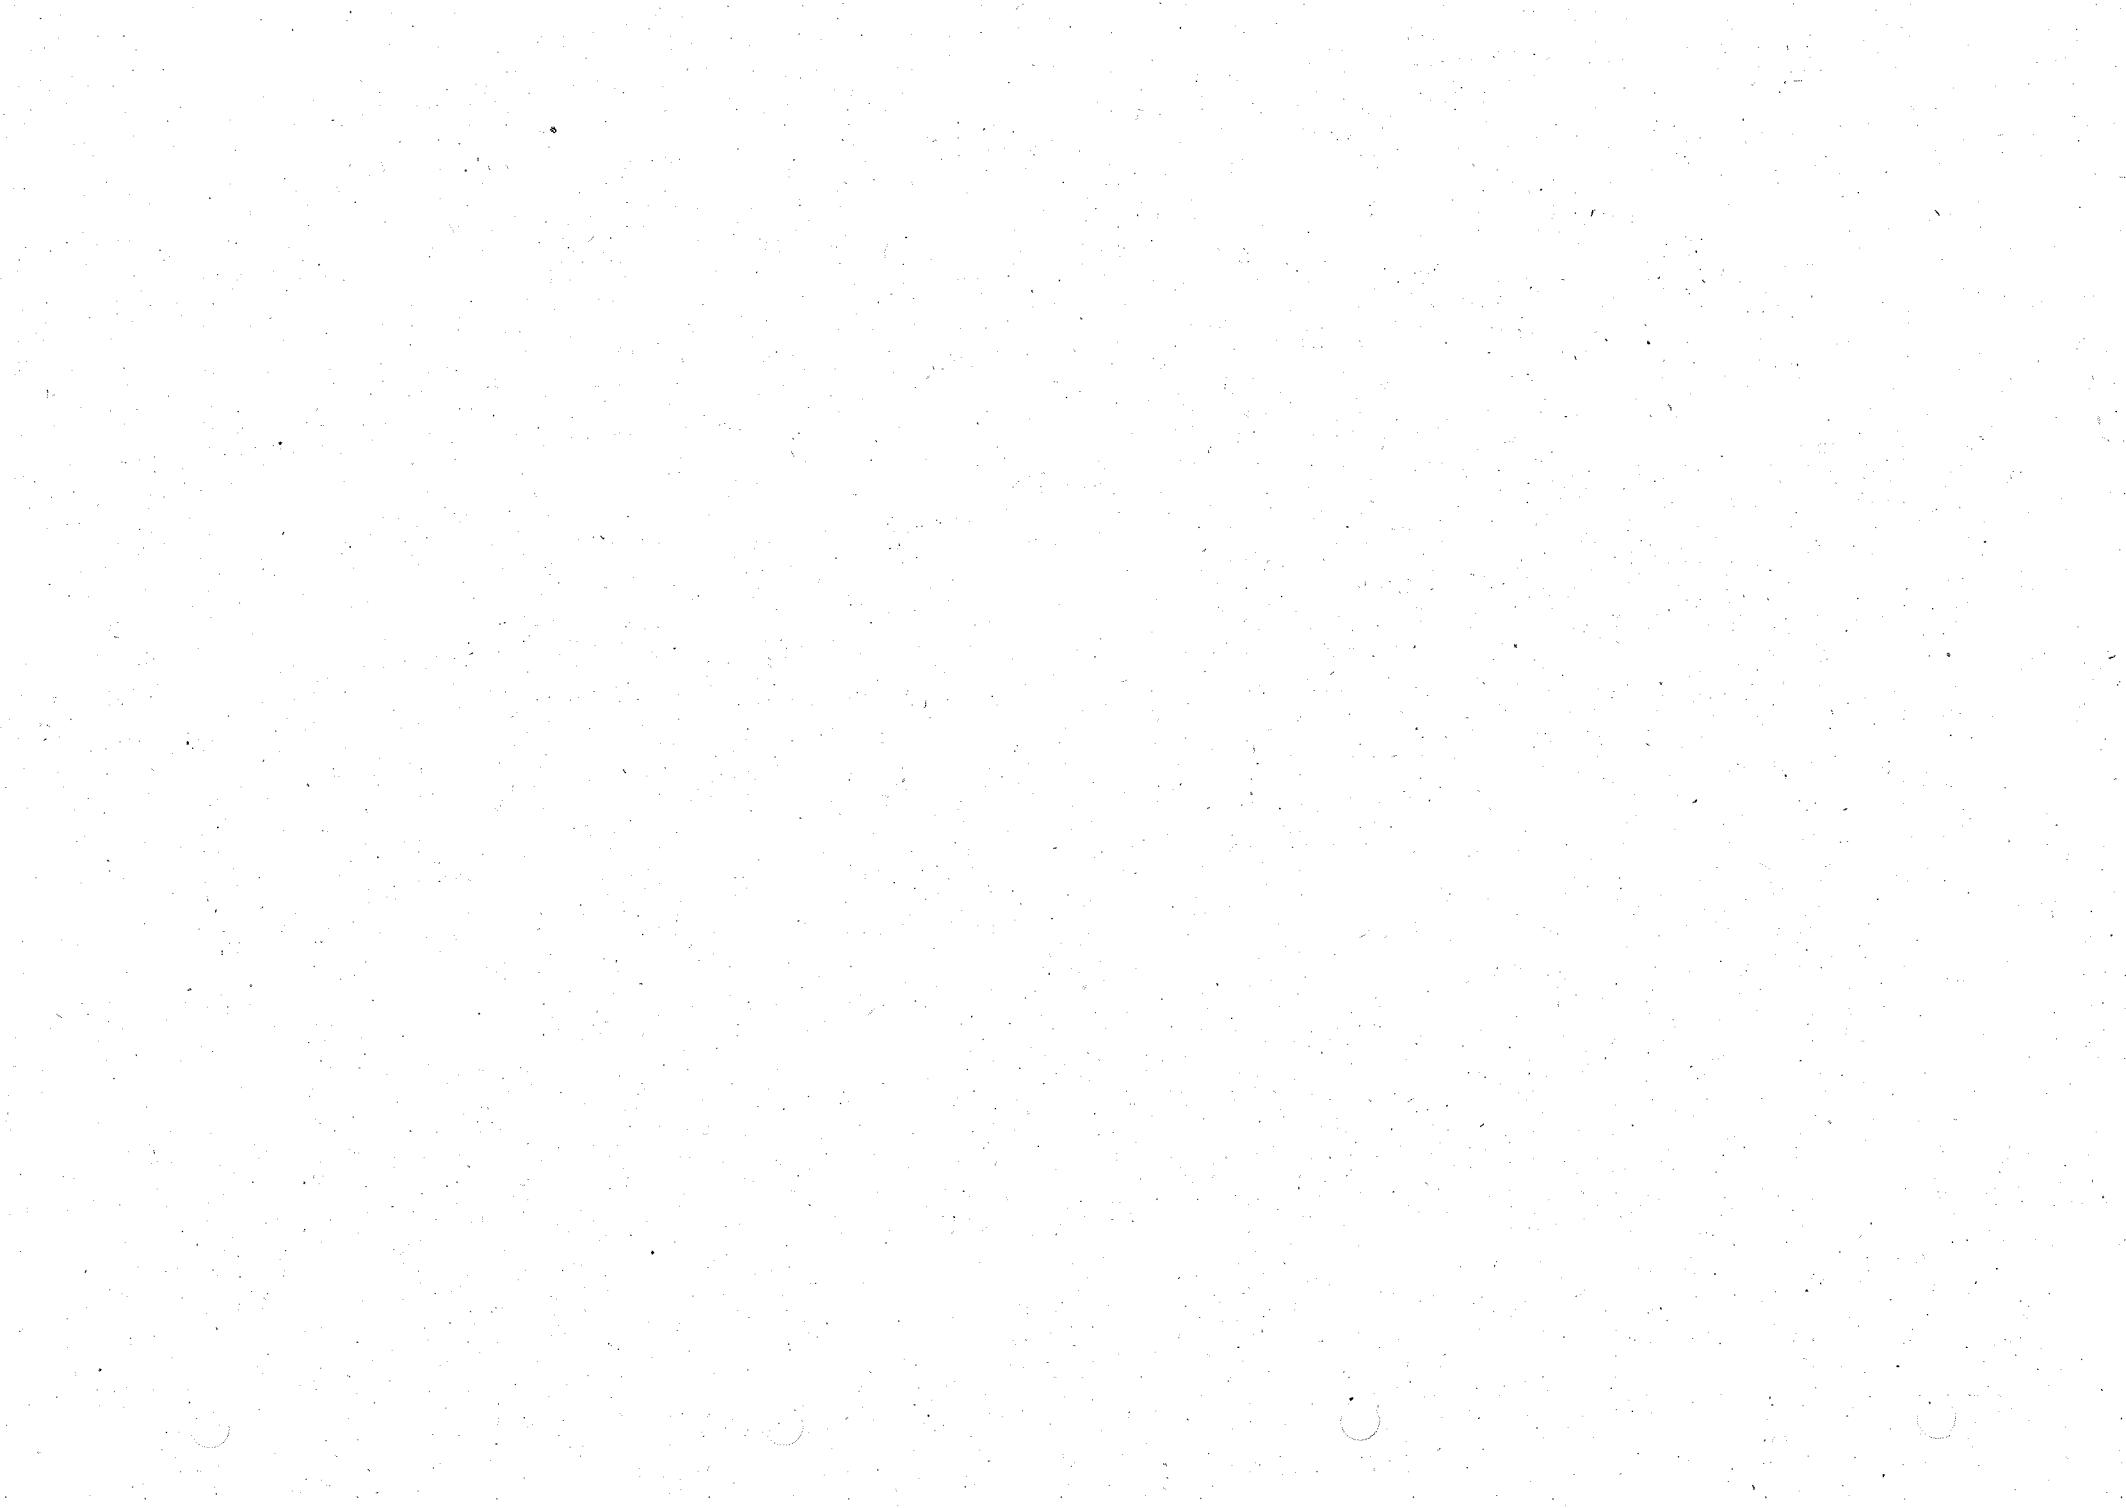
Clustering languages

TABLE 12.3 NUMERALS IN 11 LANGUAGES

English (E)	Norwegian (N)	Danish (Da)	Dutch (Du)	German (G)	French (Fr)	Spanish (Sp)	Italian (I)	Polish (P)	Hungarian (H)	Finnish (Fi)
one	en	een	eens	eins	un	uno	jeden	egy	yksi	kaksi
two	to	toee	twee	zwei	deux	dos	dwa	ketto	kolme	kolme
three	tre	tre	drie	drei	trois	tres	tre	harom	neua	neua
four	fire	fire	vier	vier	quatre	cuatro	quattro	nagy	viisi	viisi
five	fem	fem	vijf	funf	cinq	cinco	piec	öt	kuusi	kuusi
six	seks	seks	zes	sechs	six	seis	sześć	hat	seitseman	seitseman
seven	sju	sju	zeven	sieben	sept	siete	sette	het	kahdeksan	kahdeksan
eight	atte	atte	acht	acht	huit	ocho	otto	nyolc	yhdeksan	yhdeksan
nine	nin	nin	negen	neun	neuf	nueve	nove	dziewiec	kilenc	kymmenen
ten	ti	ti	tien	zehn	dix	diez	dziesięc	tiz		

Concordance of first letters= ...

En	No	Da	Du	Ge	Fr	Sp	It	Pol	Hu	Ei
En	10	8	8	3	4	4	4	3	1	1
No	8	10	9	5	6	4	4	3	2	1
Da	8	9	10	4	5	4	5	4	2	1
Du	3	5	4	10	5	1	1	0	2	1
Ge	4	6	5	5	10	3	3	2	1	1
Fr	4	4	4	1	3	10	8	9	5	0
Sp	4	4	5	1	3	9	9	10	6	0
It	3	3	4	0	2	5	7	6	10	0
Pol	1	2	2	1	0	0	0	0	10	2
Hu	1	1	1	1	1	1	1	1	1	2
Hu										10



Clustering languages

TABLE 12.3 NUMERALS IN 11 LANGUAGES

English (E)	Norwegian (N)	Danish (Da)	Dutch (Du)	German (G)	French (Fr)	Spanish (Sp)	Italian (I)	Polish (P)	Hungarian (Hu)	Finnish (Fi)
one	en	en	een	eins	un	uno	uno	jeden	egy	yksi
two	to	to	twee	zwei	deux	dos	due	dwa	két	kaksi
three	tre	tre	drie	drei	trois	tres	tre	trzy	harom	kolme
four	fire	fire	vier	vier	quatre	cuatro	quattro	cztery	nagy	neua
five	fem	fem	vijf	vijf	cinq	cinco	cinque	pięć	öt	vissi
six	seks	seks	zes	sechs	six	seis	sei	szesc	hat	kuusi
seven...	sju	syv	zeven	sieben	sept	siete	sette	siedem	het	seitsemän
eight	atte	otte	acht	acht	huit	ocho	otto	osiem	nyolc	kahdeksan
nine	nin	nine	negen	neun	neuf	nueve	nove	dziewiec	kilenc	yhdeksan
ten	ti	ti	tien	zehn	dix	diez	dieci	dziesiec	tiz	kymmenen

Concordance of first letters= ...

	En	No	Da	Du	Ge	Fr	Sp	It	Pol	Hu	Fi
En	10	8	8	3	4	4	4	4	3	1	1
No	8	10	9	5	6	4	4	4	3	2	1
Da	8	9	10	4	5	4	5	5	4	2	1
Du	3	5	4	10	5	1	1	1	0	2	1
Ge	4	6	5	5	10	3	3	3	2	1	1
Fr	4	4	4	1	3	10	8	9	5	0	1
Sp	4	4	4	4	1	3	8	10	9	7	0
It	4	3	3	4	0	2	5	7	6	10	0
Pol	1	2	2	2	2	1	0	0	0	10	2
Hu	1	1	1	1	1	1	1	1	1	2	10



$$\begin{aligned}
 & \left\langle n_H(t+1) \right\rangle > \frac{\bar{f}_H(t)}{\bar{f}(t)} n_H(t) \left(1 - p_c \frac{S(H)}{l-1} \right) (1 - p_m) S_m(H)
 \end{aligned}$$

↓
 # de esperado
 de instauración
 de H.

↓
 fitness
 de especie

↓
 media
 del fitness

↓
 long. de los
 cromosomas

↓
 Prob. de
 cruce = 1

↓
 long. del
 esqueleto.

↓
 Prob. de
 mutar

↓
 # de bits
 que vienen
 definidos
 dentro del
 esqueleto

* Cuando los bits entran en
 un extremo $S_C = 0$

diff: long. del espejismo. (long. de máx. de una bit definido a uno).

$$\text{Dim : } \begin{array}{l} 1 * * * = \emptyset \\ * 1 0 * * = 1 \\ 1 * * * 0 = 4 \end{array}$$

Su: Prob. de mutació.
que sobreiria a la

Sesión 3: Bases de Selección

Sc : Prob. de chance que sobreiviva esse

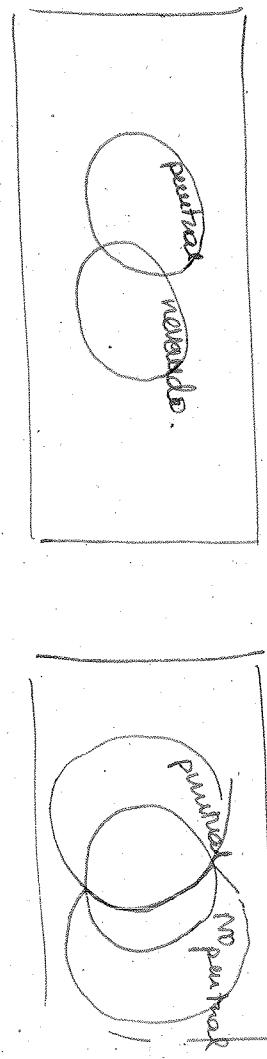


AGE	PRESCRIPTION	ASTIGMATISM	TEAR RATE	LENSES
young	myope	no	reduced	no
young	myope	no	normal	soft
young	myope	yes	reduced	no
young	myope	yes	normal	hard
young	hypermetrope	no	reduced	no
young	hypermetrope	no	normal	soft
young	hypermetrope	yes	reduced	no
young	hypermetrope	yes	normal	hard
pre-pres	myope	no	reduced	no
pre-pres	myope	no	normal	soft
pre-pres	myope	yes	reduced	no
pre-pres	myope	yes	normal	hard
pre-pres	hypermetrope	no	reduced	no
pre-pres	hypermetrope	no	normal	soft
pre-pres	hypermetrope	yes	reduced	no
pre-pres	hypermetrope	yes	normal	soft
pre-pres	hypermetrope	yes	normal	no.
pre-pres	hypermetrope	no	reduced	no.
presbyopic	myope	no	normal	no.
presbyopic	myope	yes	reduced	no.
presbyopic	myope	yes	normal	hard
presbyopic	hypermetrope	no	reduced	no.
presbyopic	hypermetrope	no	normal	soft
presbyopic	hypermetrope	yes	reduced	no.
presbyopic	hypermetrope	yes	normal	no.

$$P(\text{cond. Adv}) = 98\% \times 20\% + 2\% \cdot 70\% = 0'196 + 0'014 = 0'21 = 21\%$$

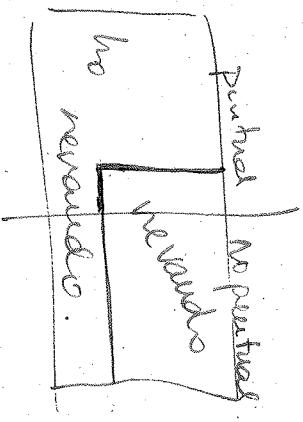
$$P(\text{Portugal} | \text{Nieve}, I) = \frac{P(\text{Nieve} | \text{Portugal}, I) \cdot P(\text{Portugal})}{P(\text{nieve})} =$$

$$= \frac{20\% \cdot 98\%}{0'21} = \frac{0'196}{0'21} = 0'93 \approx 93\%$$



$$A \rightarrow B. \quad P(B | A, A \rightarrow B) = \frac{P(A | B, A \rightarrow B) \cdot P(A)}{P(B)}$$

$$B \rightarrow A.$$



(H) D,

REGRESIÓN LOGÍSTICA

parciales 5

\bar{w} → vector selectivo entre $[-0'5, 0'5]$ (no puedes dar)

\bar{x} → valores de las columnas donde $x_0 = 1$

x_0	x_1	x_2	x_3	x_4	t
...
...

$$\text{Sigmoidal: } \tilde{J}(\tilde{w}^\top \tilde{x}_i) = -\frac{1}{1 + e^{\tilde{w}^\top \tilde{x}_i}}$$

PROCAS: permite ajustar los valores y se produce aleatorizar los datos por cada época para mejorar la época se puede variar los para crear la recta los datos.

AJUSTE DE LA RECTA \bar{w} :
 vector que define el hiperplano

$\tilde{w} = \bar{w} - \eta (\tilde{x}_i - t_i) \tilde{x}_i$

ejemplo de clase 1

$$\text{EJEMPLO: } \bar{w} = (0'5, 0'6, -0'2) \quad \tilde{w}^\top = \begin{pmatrix} 0'5 \\ 0'6 \\ -0'2 \end{pmatrix}$$

$$\tilde{x}_i = (1, 3, 1) \quad y = 2$$

$$\tilde{w}^\top \tilde{x}_i = (0'5, 0'6, -0'2) \cdot (1, 3, 1) = 0'5 \cdot 1 + 0'6 \cdot 3 + (-0'2) \cdot 1 = 2'4$$

$$\tilde{J}(2'4) = -\frac{1}{1 + e^{2'4}} = \underline{0'40}$$

ejemplo de clase 2

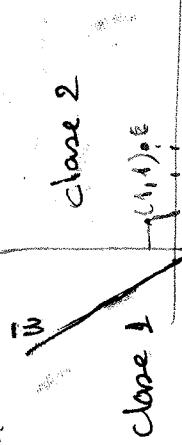
$$\text{Actualización } \bar{w}: \quad \bar{w} = (0'5, 0'6, -0'2) - 2 (0'4 - 1) \cdot (1, 3, 1) = (0'5, 0'6, -0'2) - (0'8, 1'2, 1'8) = (2'3, 6, 1'6)$$

calculando recta:
 recta: $y = w_0 + w_1 x + w_2 y \rightarrow 2'3 + 6x + 1'6y$

$$x=0 \rightarrow y = -1'43$$

$$y=0 \rightarrow x = -0'38$$

$$\text{calculando } (0,0) \quad \tilde{J}(2'3) = 0'09$$



Prop. por MAP.

Cambia la
actualización
de \bar{w}

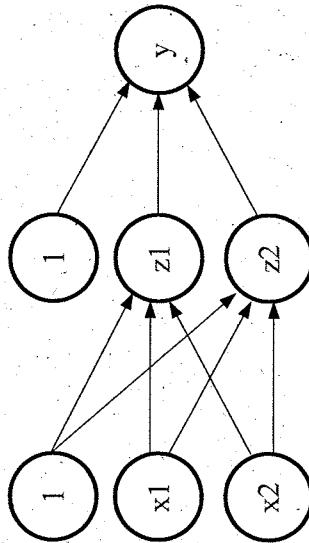
$$\bar{w} = \bar{w} - \eta (\bar{v}_i - t_i) \bar{x}_i - \frac{\eta}{N\sigma^2} \bar{w}$$

\swarrow varianza (la don)
 \downarrow 1º ejemplo

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

1. Given the following instances, obtain a valid set of weights for the neural network architecture shown in figure in order to get all examples correctly classified and compute the values of the z variables. The activation functions are all step functions.

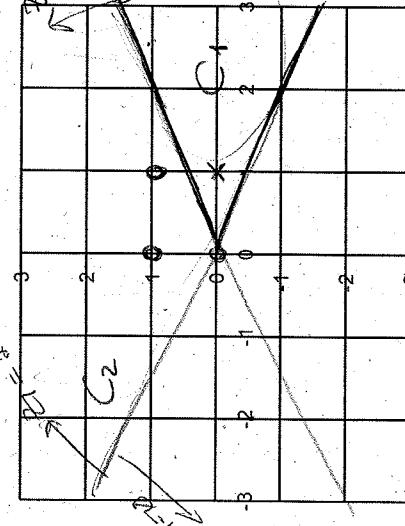
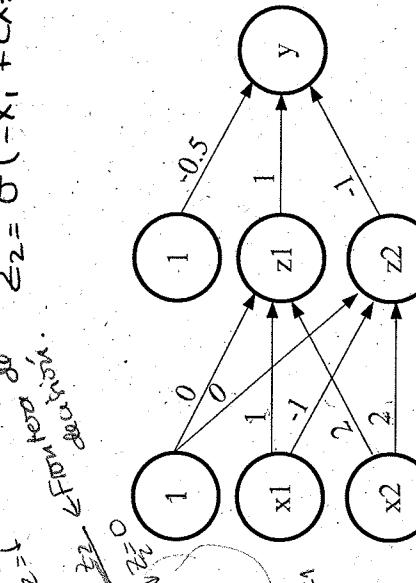
x_1	x_2	t	z_1	z_2
0	0	0		
0	1	0		
1	0	0		
1	1	0		
0,5	0,5	1		



2. Draw the decision boundary of the following neural network

$$z_1 = \Theta(x_1 + 2x_2)$$

$$z_2 = \Theta(-x_1 + 2x_2)$$

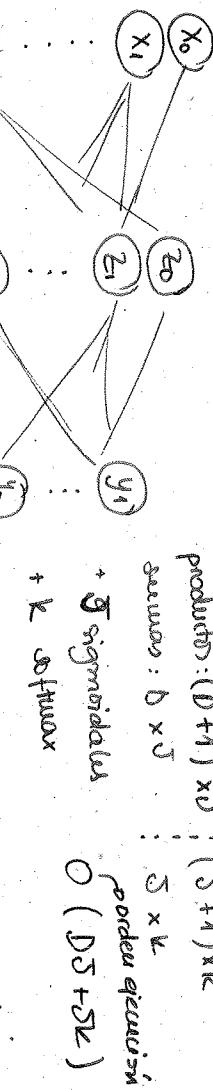


z_1	z_2	$y = \Theta(-0.5 + z_1 - z_2)$	Class
0	0	0	C2
0	1	0	C2
1	0	1	C1
1	1	1	C1

3. We would like to solve a classification problem with 5 classes, 50 attributes and 1000000 training instances using a neural network with one hidden layer containing 9 neurons (z_1, z_2, \dots, z_9). Ten training epochs will be executed. Compute the number of weight updates that have to be carried out during the training phase.

$$\text{Cálculo: } 0(DS + SK) \quad | \quad \text{nº pasos} = (D+1) \times S + (S+1) \times K \\ \text{entrenamiento:} \quad | \quad \text{nº epochs} = 10 \quad N = 100.000 \\ \text{nº actualizaciones} = \text{epochs} \times N \times \text{nº pasos}$$

4. Compute the number of necessary operations to classify an instance using the network described in the previous exercise.



5. We would like to train a Rosenblatt perceptron for a problem with 4 attributes. The weights are $w = \{0.1 - 0.1 0 0.1 - 0.1\}$. Compute the weight update for the example $x = \{1 1 0 1\}$ of class $t=1$ using 0.25 as learning coefficient.

$$y(\bar{x}) = \Theta \left(\sum_{i=0}^D x_i w_i \right) = \Theta(-0.1) = 0$$

$$\sum_{i=0}^D x_i w_i = 0.1 - 0.1 + 0 + 0.1 - 0.1 = 0.1$$

$$\bar{w} = \bar{w} - \gamma (y(\bar{x}) - t) \bar{x} = \begin{pmatrix} 0.1 \\ 0.1 \\ 0 \\ 0.1 \end{pmatrix} - 0.25 (0-1) \begin{pmatrix} 1 \\ 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0.35 \\ 0.15 \\ 0.25 \\ 0.1 \end{pmatrix} - 0.15 = \begin{pmatrix} 0.2 \\ 0.05 \\ 0.1 \\ 0.05 \end{pmatrix}$$

La vie au quotidien

1

Complétez cet article à l'aide de mots choisis dans la liste suivante. Faites les transformations nécessaires.

LEXIQUE

look - porter - soigner - vêtement - tenue vestimentaire - classique - présentation - apparence - image - négligé - pied - confort - adapté - exceptionnel - chic - code vestimentaire - shabbier - friction

Quand l'habit fait le moine...

« Dis-moi ce que tu et je te dirai qui tu es. » Loin de n'être que secondaire, la a une grande importance lors d'un entretien de recrutement. Elle fait partie des signes perçus par votre intervieweur pour se faire une bonne ou une mauvaise de vous.

Rien de plus superficiel que le pensez-vous ? Erreur ! Votre en dit parfois plus sur vous qu'un long discours. Lors d'un entretien d'embauche, votre joue donc un vrai rôle. Si certaines entreprises en parlent dans leurs annonces avec des formules du type « présentation exigée », d'autres ne l'évoquent pas forcément, mais y accordent tout autant d'importance.

La tête de l'emploi

Un look à l'entreprise vous permettra d'abord de vous rassurer et en même temps d'indiquer à votre intervieweur que vous vous fondez dans la culture de l'entreprise.

Dépêche Rédaction n° 127, janvier 2006.

1 (TAXIS) Un taxi golpea a una persona de noche y huye. En la ciudad operan dos compañías de taxis: la verde y la azul. El 85 % de los taxis de la ciudad son verdes y el 15 % restante, azules.

1. ¿Cuál es la probabilidad de que el taxi del accidente fuera azul?
2. Aparece una testigo que identifica el taxi como azul. El jurado estima la fiabilidad de la testigo en un 80 %. ¿Cuál es la probabilidad ahora de que el taxi del accidente fuera azul?
3. Decisión final usando el criterio de máxima verosimilitud y el criterio de máxima probabilidad a posteriori

2 (NO CAUSAL) Las probabilidades pueden representar conexiones lógicas, no causales. Consideremos una urna con 6 bolas blancas y 6 negras.

1. Si en la primera extracción se ha eliminado una bola blanca, ¿Cuál es la probabilidad de extraer una bola blanca en una segunda extracción?
2. Por el contrario, supongamos que la segunda extracción ha sido blanca, ¿Cuál es la probabilidad de que la primera fuera blanca también?

3 (LLUVIA) Según el hombre del tiempo la probabilidad de lluvia hoy es del 20 %. Estamos en un sótano sin ventanas y no podemos saber qué tiempo hace fuera. Sin embargo, vemos entrar a alguien llevando un paraguas. Sabiendo que la probabilidad de que alguien lleve un paraguas y esté lloviendo es del 70 % y solo del 10 % en caso contrario ¿Cuál es la probabilidad de que esté lloviendo?

4 (BOLSAS) Hay dos bolsas: A y B. La bolsa A contiene 2 bolas negras y 3 blancas. La B, 3 negras y 2 blancas. Se selecciona una bolsa al azar y se extrae una bola.

1. Calcular la probabilidad de que la bola sea negra.
2. Si la bola obtenida ha sido negra calcular qué bolsa es la más probable que hayamos elegido.
3. Decisión final usando el criterio de máxima verosimilitud y el criterio de máxima probabilidad a posteriori

5 (BOLSAS 2) Hay dos bolsas: A y B. La bolsa A contiene 2 bolas negras y 3 blancas. La B, 3 negras y 2 blancas. Se selecciona una bolsa al azar, teniendo en cuenta que la bolsa A tiene un 75 % de probabilidad de ser elegida, y se extrae una bola.

1. Calcular la probabilidad de que la bola sea negra.
2. Si la bola obtenida ha sido negra calcular qué bolsa es la más probable que hayamos elegido.
3. Decisión final usando el criterio de máxima verosimilitud y el criterio de máxima probabilidad a posteriori



Verosimilitud

Anchura de pétalos	setosa	versicolor	virginica
0 - 0.2	1/10		
0.2 - 0.4	18/25		
0.4 - 0.6	4/25		
0.6 - 0.8	1/50		
0.8 - 1.0			
1.0 - 1.2		1/5	
1.2 - 1.4		9/25	
1.4 - 1.6		17/50	3/50
1.6 - 1.8		2/25	1/25
1.8 - 2.0		1/50	8/25
2.0 - 2.2			6/25
2.2 - 2.4			11/50
2.4 - 2.6			3/25
2.6 - 2.8			
2.8 - 3.0			

$$p(a=1.5 | i=set) = 0$$

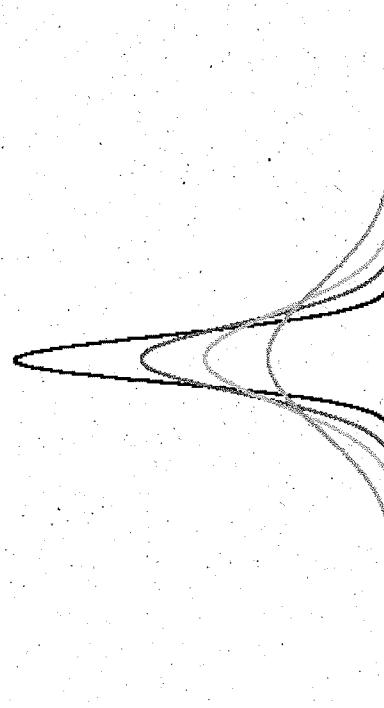
$$p(a=1.5 | i=ver) = \frac{17}{50}$$

$$p(a=1.5 | i=set) = \frac{3}{50}$$

Distribución normal

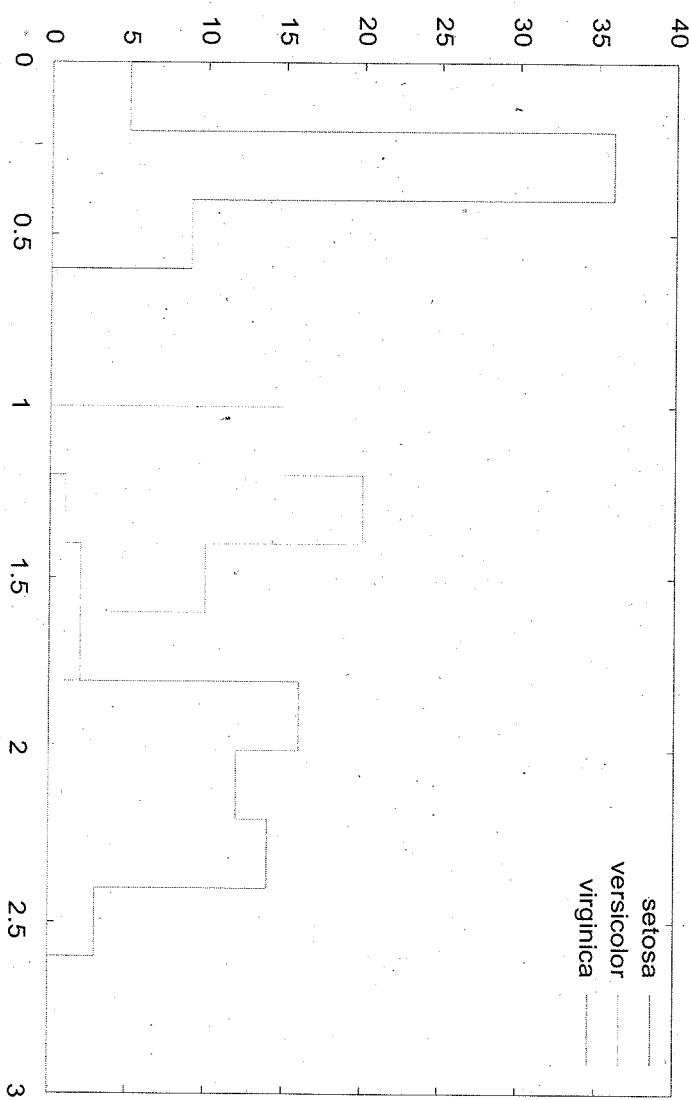
$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-m)^2}{2\sigma^2}}$$

(a) Distribuciones normales con distinta desviación estándar e igual media



Naïve Bayes para atributos cuantitativos

¿A qué clase debemos asignar una flor con anchura 1.5?



Discretización de la anchura de pétalos

Anchura de pétalos	setosa	versicolor	virginica
[0 - 0.2)	5		
0.2 - 0.4	36		
0.4 - 0.6	8		
0.6 - 0.8	1		
0.8 - 1.0			
1.0 - 1.2		10	
1.2 - 1.4		18	
1.4 - 1.6		17	3
1.6 - 1.8		4	2
1.8 - 2.0		1	16
2.0 - 2.2			12
2.2 - 2.4			11
2.4 - 2.6			6
2.6 - 2.8			
2.8 - 3.0			

— PROBABILIDAD . Introducción

12 sept '13

• lógica deductiva

* Silogismos fuertes

A	B	$A \rightarrow B$
Falso	0	1
0	1	1
1	0	0
Falso	1	1

Premsa : Si A \rightarrow B y observamos A , entonces B es cierto.
Ademá, si observamos B entonces A no es cierto.

* Silogismos débiles

- Si B es cierto entonces A es más probable
- Si A es falso entonces B es menos probable

• conceptos de probabilidad

DOMINIO : Todos los posibles resultados de un experimento aleatorio.

VARIABLE ALEATORIA : Variable que identifica al experimento aleatorio

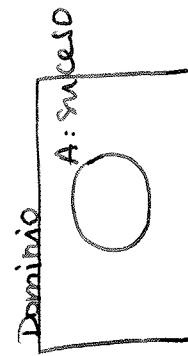
SUCESO : valor que toma la variable aleatoria al realizar el experimento aleatorio.

ej : TIRAR UN DADO

Domínio = { 1, 2, 3, 4, 5, 6 }

Variable = X

Sucesos = x = 1 , ... , x = 6



$P(A|I)$ donde A es el suceso e I la información

REGULAS

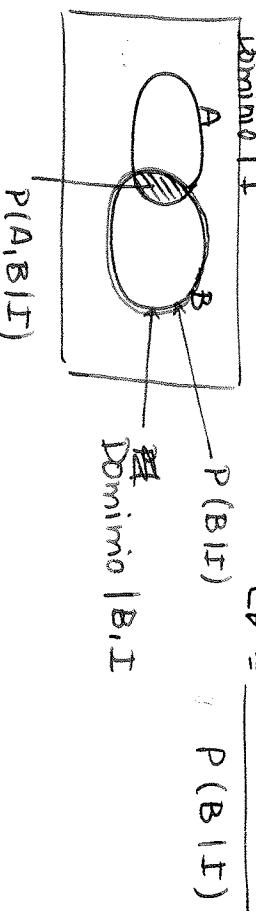
$$1) P(A|I) \in [\emptyset, 1]$$

$$2) P(\text{true}) = 1, \quad P(\text{false}) = \emptyset$$

$$3) P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$4) \text{Regla de la suma: } P(A|I) + P(\bar{A}|I) = 1$$

$$5) \text{Regla del producto: } P(A \cap B|I) = \frac{P(A|B,I)}{P(B|I)} \cdot P(B|I)$$



$$P(A \cap B|I)$$

PROBABILIDAD VÍA TÓICA DEDUCTIVA

13 Sept '13

$P(A|I) + P(\bar{A}|I) = 1$ en el limite $P(A|I)$

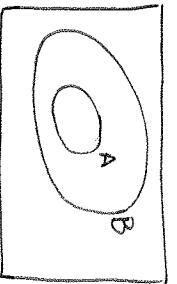
Sucogreso fuerte

$$I = A \Rightarrow B$$

$$P(B|A, A \Rightarrow B) = \frac{P(A, B|A \Rightarrow B)}{P(A|A \Rightarrow B)} = \frac{P(A|A \Rightarrow B)}{P(A|A \Rightarrow B)} = 1$$

aplicando la regla del producto.

$$P(A|\bar{B}, A \Rightarrow B) = \frac{P(A, \bar{B}|A \Rightarrow B)}{P(\bar{B}|A \Rightarrow B)} = \frac{\emptyset}{P(\bar{B}|A \Rightarrow B)} = \emptyset$$



• Teorema de Bayes

$$P(A|B, I) = \frac{P(B|A, I) P(A|I)}{P(B|I)}$$

$$P(H|D, I) = \frac{P(D|H, I) P(H|I)}{P(D|I)}$$

$P(H|I)$ = Probabilidad a priori, confianza en H antes de ver datos

$$P(D|H, I) \equiv \text{Verosimilitud de los datos } D \text{ si } H \text{ es cierta.}$$

$P(H|D, I)$ = Probabilidad a posteriori
 En la Ciudad operan 2 empresas de taxis: La verde y la azul.
 En la Ciudad operan 2 empresas de taxis: La verde y la azul.
 Son 15% azules y el 85% verdes. Y el 15% azules son verdes.

Cuál es la prob. de que

accidente fuera azul? Aparece como azul
 testigo que identifica el taxi como azul
 la fiabilidad del testigo es del 80%.

la prob. ahora de que el taxi fuera azul es la prob. final

$$P(H = \text{azul}|I) = 15\% \quad P(H = \text{verde}|I) = 85\%$$

D = testigo dice azul confianza del 80%

$$P(H = \text{azul} | D = \text{azul}, I) = \frac{P(D = \text{azul} | H = \text{azul}, I) P(H = \text{azul} | I)}{P(D = \text{azul} | H = \text{verde}, I) P(H = \text{verde} | I)} = 0'41$$

$$= \frac{P(D = \text{azul} | I)}{P(D = \text{verde} | I)} = \frac{0'2}{0'8} = 0'25$$

Más probable que sea verde.

$$P(D = \text{azul} | I) = P(D = \text{azul}, H = \text{azul} | I) + (D = \text{azul}, H = \text{verde} | I) =$$

$$= P(D = \text{azul} | H = \text{azul}, I) P(H = \text{azul} | I) + P(D = \text{azul} | H = \text{verde}, I) P(H = \text{verde} | I) =$$

$$= 0'2 \cdot 0'85 + 0'8 \cdot 0'15 = 0'29$$

MAP: $\max(0'41, 0'59) = 0'59$ más prob. que fuera verde

MV: $\max(0'85, 0'2) = 0'8$ más prob. que fuera azul

Ej: Hay dos bolsas: A y B. La bolsa A contiene dos bolas negras y 3 blancas. La B, 3 negras y 2 blancas.

- Si la bola obtenida ha sido negra, calcular qué bolsa es la más probable que hayan sido elegido.

$$P(H=A | D=\bullet, I) = \frac{2/5 \cdot 1/2}{1/2} = 2/5$$

$$P(H=B | D=\bullet, I) = \frac{3/5}{\text{más probable}} \quad \text{El resto.}$$

Ej: Hay dos bolsas: A y B



• Calcular la prob. de que la bola sea negra:

$$P(D=\bullet | I) = 0.75 \cdot 2/5 + 0.25 \cdot 3/5 = 9/20$$

- Si la bola obtenida ha sido negra, calcular qué bolsa es la más probable que hayan sido elegido.

$$P(H=A | D=\bullet, I) = \frac{P(D=\bullet | H=A, I) P(H=A | I)}{P(D=\bullet | I)} = \frac{2/5 \cdot 0.75}{9/20} = \frac{2/3}{\text{más prob.}}$$

$$P(H=B | D=\bullet, I) = \frac{P(D=\bullet | H=B, I) P(H=B | I)}{P(D=\bullet | I)} = \frac{3/5 \cdot 0.25}{9/20} = 1/3$$

TOMA DE DECISIONES

OBJETIVO: Elección la hipótesis H_i de entre H_1, H_2, \dots, H_e

"a la mitad" de los datos D.

- Máxima probabilidad a posteriori (MAP) + correcta

$$H_i = \max_i P(H_i | D) = \max_i \frac{P(D | H_i) P(H_i)}{P(D)}$$

$$= \boxed{\max_i P(D | H_i) P(H_i)}$$

Ej 2: (NO CAUSAL) Las probabilidades pueden representar conexiones lógicas, no causales. Consideremos una urna con 6 bolas blancas y 6 bolas negras

- Si en la 1^a extracción se ha eliminado una bola blanca, ¿cuál es la prob. de extraer una bola blanca en la 2^a extracción?

$$P(\text{segunda} = 0 \mid \text{primera} = 0) = 5/11$$

- Por el contrario, supongamos que la 2^a extracción ha sido blanca, ¿cuál es la prob. de que la 1^a fuera blanca también?

APLICANDO BAYES ...

$$P(p=0 \mid s=0) = \dots = \frac{5/11 \cdot 6/12}{P(s=0)} = 5/11$$

$$P(p=0 \mid s=0) = \dots = \frac{6/11 \cdot 6/12}{P(s=0)} = \boxed{6/11} \quad \text{Decisión por MAP}$$

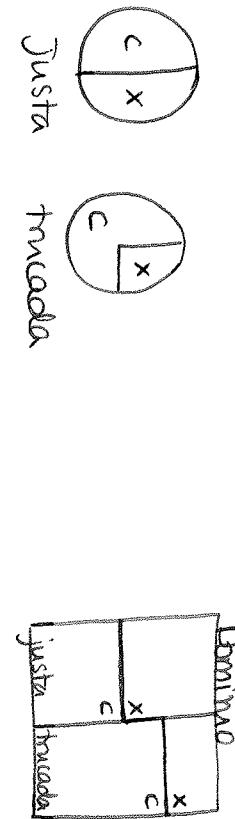
$$P(s=0) = \underbrace{5/11 \cdot 6/12 + 6/11 \cdot 6/12}_{\text{número de los numeradores}} =$$

Ej 3: Según el número del tiempo la prob. de lluvia hoy es del 20%. Estamos en un sótano sin ventanas y no podemos saber qué tiempo hace fuera. Si en embargo, venimos entrar a alguien llevando un paraguas y sabiendo la prob. de que alguien lleve un paraguas y este siendo el del 70% y solo del 10% en caso contrario. ¿Cuál es la prob. de que está lloviendo?

$$P(\text{estar lloviendo}) = \frac{0.7 \cdot 0.2}{0.7 \cdot 0.2 + 0.8 \cdot 0.1} = \frac{0.14}{0.14 + 0.08} = 63\%$$

monedas

Saco con monedas justas y truncadas



- $\rightarrow D=c$

$$P(H=j | D=c) = \frac{P(D=c | H=j) P(H=j)}{P(D=c)} = \frac{0^{'}5 \cdot 0^{'}5}{P(D=c)} = 0^{'}4$$

- $\rightarrow D=x$

$$P(H=j | D=x) = 0^{'}67$$

$$P(H=t | D=x) = 0^{'}33$$

4 modelos (o clasificadores)

$$D \in \{c, x\} \Rightarrow H \in \{t, j\}$$

modelo h_1	modelo h_2	modelo h_3	modelo h_4
$h_1(c) = t$	$h_2(c) = j$	$h_3(c) = j$	$h_4(c) = t$
$h_1(x) = j$	$h_2(x) = t$	$h_3(x) = j$	$h_4(x) = t$

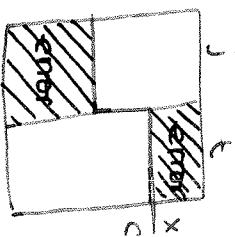
¿Cuál es el mejor modelo? Es que tenga menor prob. de equivocarse.

Prob. de error de h_1

$$h_1(x) = j \quad P(\text{error}_1) = P(H=j, D=c) +$$

$$h_1(c) = t \quad P(H=t, D=x) =$$

$$= P(D=c | H=j) P(H=j) + P(D=x | H=t) P(H=t)$$

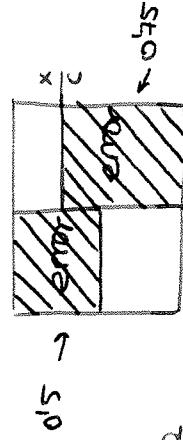


fallo del 37'5%

fallo de H_2

$$h_2(c) = j \quad p(\text{error}_2) = 0'5 \cdot 0'5 + 0'45 \cdot 0'5 = 0'625$$

$$h_2(x) = t$$



Fallo de H_3 y H_4 = 50%, por lo que
el mejor modelo es H_1

REGLA DE BAYES SIMÉTRICA (se conoce el modelo que tiene ~ mayor prob. al aplicar Bayes)
El mejor modelo es el que clasifica cada ejemplo con la clase que tiene la mayor prob. a posteriori.

Es decir, si $D=c$ diremos $h(c)=j$ si $P(H=j|D=c) > P(H=t|D=c)$. Diremos $h(c)=t$ si $P(H=t|D=c) > P(H=j|D=c)$

$$P(H=j|D=c) + P(H=t|D=c) = 1 \text{ decidimos } h(c) = j \text{ si}$$

$$P(H=j|D=c) > 1 - P(H=j|D=c)$$

$$P(H=j|D=c) > \frac{1}{2} \quad \begin{array}{c} + \\ 0 \\ - \end{array} \quad \begin{array}{c} 0'5 \\ j \\ 1 \end{array} \quad P(H=j|D=c)$$

20 sept

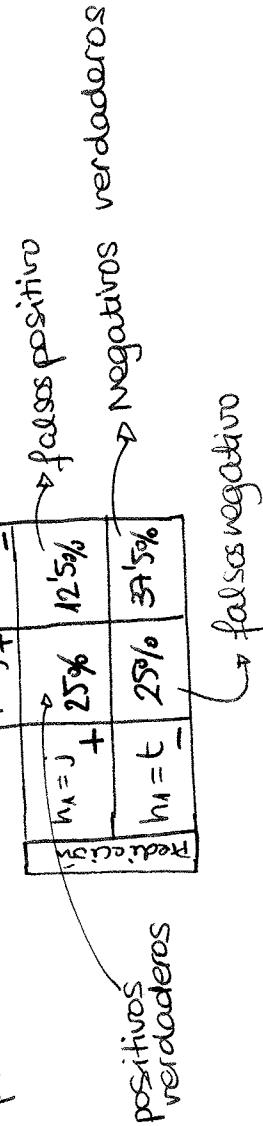
MATRIZ DE CONFUSIÓN

Forma de visualizar el error en tabla por modelo.

- columnas = clase real
- filas = clase predicha por el clasificador.

N.C. para H_1 :

		REAL	
		$H=j$	$H=t$
prediccion	$H=j$	25%	12'5%
	$H=t$	25%	37'5%



REGLA ASIMÉTRICA DE BAYES

- Suponemos un riesgo (coste) R' si pasamos t por j
- R' j por t

Def: Matriz de coste

$M=j$	$M=t$
$H=j$	$0 \quad R$
$H=t$	$R' \quad 0$

$$\begin{aligned} & \text{Si } D=c \\ & P(M=j | D=c) = \frac{j}{R + P(M=t | D=c)} \\ & P(M=t | D=c) = \frac{t}{R'} \end{aligned}$$

'Cuál es el costo si $D=c$ y clasificamos como:

$$M(c)=j : P(M=t | D=c) \times R$$

$$M(c)=t : P(M=j | D=c) \times R'$$

Si $D=c$

$$P(M=j | D=c) = \frac{j}{R + P(M=t | D=c)}$$

$$\left\{ \begin{array}{ll} j & \text{si } M(c)=j \\ t & \text{si caso contrario} \end{array} \right.$$

dado que $P(M=t | D=c) + P(M=j | D=c) = 1$

diciendo $M(c)=j$ si $R \times (1 - P(M=j | D=c)) < R \times P(M=j | D=c)$

$$P(M=j | D=c) > \frac{R}{R + R'}$$

Ejemplo: $R = 2R'$

$$P(M=j | D=c) > \frac{2R'}{R' + 2R'} = \frac{2}{3}$$

\downarrow

$\frac{\text{falsa}}{0} \quad \frac{\text{justa}}{1}$

Def: Si tenemos dos hipótesis H_1 y H_2 y si al elegir H_1 se corre un riesgo R y si elegimos H_2 , se corre un riesgo R' , entonces hay que elegir H_1 si $P(H_1 | D) > \frac{R}{R+R'}$ y H_2 en el caso contrario

Ejemplo (MONEDAS)

$$\text{Si } R = 3R' \quad \text{¿ } h_1, h_2, h_3 \text{ ó } h_4? \quad \text{en riesgo}$$

$$\begin{cases} h_1(c) = t \\ h_1(x) = j \end{cases}$$

riesgo $h_1 = R \cdot P(H=j, D=c) + R' \cdot P(H=t, D=x) =$
 $= 3R \cdot (0'625) + R' \cdot (0'375) = R \cdot 0'625$

$$= R \cdot P(D=c | H=j) P(H=j) + 3R' \cdot P(D=x | H=t) P(H=t) =$$
 $= R' \cdot 1/4 + 3R' \cdot 1/8 = 3R' \frac{5}{8} = \underline{\underline{R' \cdot 0'625}}$

* Calcular h_2, h_3 y h_4 .

25 Sept '13

$$\begin{aligned} \text{riesgo } h_2 &= R \cdot P(c, t) + R' \cdot P(x, j) = \\ \begin{cases} h_2(c) = j \\ h_2(x) = t \end{cases} &= R \cdot P(c, t) P(t) + R' \cdot P(x | j) P(j) = \\ &= 3R' \cdot 0'75 \cdot 0'5 + R' \cdot 0'5 \cdot 0'5 = \underline{\underline{R' \cdot 1'375}} \end{aligned}$$

riesgo $h_3 = P(h_3=j, t) \cdot R + P(h_3=t, j) \cdot R' =$

$$\begin{cases} h_3(c) = j \\ h_3(x) = j \end{cases}$$

$$= 0'75 \cdot 0'5 \cdot 3R' + 0'25 \cdot 0'5 \cdot R' = \underline{\underline{1'5R'}}$$

$$\text{riesgo } h_4 = P(c, j) R' + P(x, t) R =$$

$$\begin{cases} h_4(c) = t \\ h_4(x) = t \end{cases}$$

$$= P(c, j) R' + P(x, t) R = \underline{\underline{0'5R'}}$$

Hipótesis con lo que le conviene

se escoge → menor riesgo.

por la regla armónica de Bayes.

riesgo $h_4 = \frac{P(h_4=j | D=x)}{P(h_4=t | D=x)} = \frac{1/3}{1/5} > \frac{R'}{R+R'} = 0'25 \rightarrow$ si la cumple

Logaritmo de errores de Bayes X

$$\left\{ \begin{array}{l} P(h_4=j | D=x) = 1/3 > \frac{R'}{R+R'} = 0'25 \rightarrow \text{No lo cumple.} \\ P(h_4=t | D=x) = 3/5 > \frac{R'}{R+R'} = 0'25 \rightarrow \text{lo cumple} \end{array} \right.$$

$$\left\{ \begin{array}{l} P(h_3=j | D=x) = 2/5 > \frac{R'}{R+R'} = 0'25 \rightarrow \text{No lo cumple.} \\ P(h_3=t | D=x) = 3/5 > \frac{R'}{R+R'} = 0'25 \rightarrow \text{lo cumple} \end{array} \right.$$

Problema locillar

H = n, d, b (diagnóstico)

Llega paciente con $P = (l=m, p=n)$

$$P(d=n | l=m, p=n) = \frac{P(l=m, p=n | d=n) P(d=n)}{P(p=n, l=m)}$$

Probabilidades a posteriori

$$P(d=n) = \frac{15}{24} ; \quad P(d=d) = 4/24 ; \quad P(d=b) = 5/24$$

$$P(p=n, l=m | d=n) = 1/5 ; \quad P(p=n, l=m | d=d) = 2/4$$

$$P(p=n, l=m | d=b) = 2/5$$

$$P(d=n | p=n, l=m) = \frac{1/15 \cdot 15/24}{P(p=n, l=m)} = 1/6$$

$$P(d=d | p=n, l=m) = \frac{3/4 \cdot 4/24}{P(p=n, l=m)} = 1/2 \quad \leftarrow \text{mas probable}$$

$$P(d=b | p=n, l=m) = \frac{2/5 \cdot 5/24}{P(p=n, l=m)} = 1/3$$

$\boxed{P(l=m, p=n)}$

□ Decision
MAP

	$d=n$	$d=d$	$d=b$
$l=m, p=n$	1/3	1/6	1/2
$l=m, p=r$	1	0	0
$l=m, p=c$	1	0	0

$$P(H_i | x_1, \dots, x_n) = \frac{P(x_1, \dots, x_n | H_i) P(H_i)}{P(x_1, \dots, x_n)} = \frac{P(x_1 | H_i) \dots P(x_n | H_i) P(H_i)}{P(x_1, \dots, x_n)}$$

Suposición Naïve Bayes

REGLA DE DECISIÓN NAÏVE BAYES

$\text{CLASE NB} = \arg \max_{H_i} \prod_{j=1}^n P(x_j H_i) P(H_i)$ <p style="margin-left: 20px;">estimado a partir de datos.</p>

Ejemplo:

$$P(l=m, p=n | d=n) = \frac{P(l=m | d=n) P(p=n | d=n)}{\text{Sup NB}} = \frac{\frac{7}{15} \times \frac{3}{15}}{\frac{7}{15} \times \frac{3}{15} + \frac{8}{15} \times \frac{4}{15}}$$

Para calcular la clasificación NB hay que crear atributos con clases.

	n	b	d
normal	3	5	4
reducida	12	0	0

	n	b	d
normal	3	5	4
reducida	12	0	0

$(l=m, p=n)$

$$P(d=w | l=m, p=n) = \frac{P(l=m | d=n) P(p=n | d=n) P(d=n)}{P(l=m, p=n)} = \frac{7/15 \cdot 3/15 \cdot 1/15}{7/15 \cdot 3/15 + 8/15 \cdot 4/15} = \frac{1/120}{P(\dots)}$$

$$= \frac{1/120}{P(\dots)} \quad \begin{matrix} \text{Begir el mayor} \\ \text{numerador} \end{matrix}$$

$$P(d=b | l=m, p=n) = \frac{2/15 \cdot 5/15 \cdot 5/24}{P(\dots)} = \frac{1/12}{P(\dots)}$$

$$P(d=d | l=m, p=n) = \frac{3/4 \cdot 4/4 \cdot 4/24}{P(\dots)} = \frac{1/12}{P(\dots)} = \frac{1/12}{\frac{1/12}{P(\dots)}}$$

* El denominador se calcula sumando todos los numeradores.

APPROXIMACIÓN

EXACTO

$$P(d=u \mid \ell=u, p=w) = 22\%$$

17%

$$P(d=b \mid \ell=u, p=w) = 31\%$$

34%

$$P(d=d \mid \ell=u, p=r) = 47\% \rightarrow$$

50% ↗

$(\ell=m, p=r)$

$$P(d=u \mid \ell=m, p=r) = \frac{7/30}{P(\dots)} = 100\%$$

$$P(d=b \mid \ell=m, p=r) = \frac{\emptyset}{P(\dots)} = 0\%$$

$$P(d=d \mid \ell=m, p=r) = \frac{\emptyset}{P(\dots)} = 0\%$$

CORRECCIÓN DE LAPLACE

En el caso de que tengamos valores con ceros en las tablas, se añade 1 a todos los celdas.

	a	b	c
normal	3+1	5+1	4+1
reducida	12+1	0+1	0+1

Es la prob. original,
no de la nueva tabla.

$(\ell=u, p=r)$ con NB y corrección

$$P(d=u \mid \ell=u, p=r) = \frac{3/15 \cdot 13/17}{P(\dots)} = \frac{13/24}{P(\dots)}$$

$$P(d=b \mid \ell=u, p=r) = \frac{2/5 \cdot 1/4 \cdot 5/24}{P(\dots)} = \frac{1/48}{P(\dots)}$$

$$P(d=d \mid \ell=u, p=r) = \frac{3/4 \cdot 1/6 \cdot 4/24}{P(\dots)} = \frac{1/48}{P(\dots)}$$

Niveles Bajos para estimarlos cuantitativos.

Prob. a posteriori $P(\text{setosa} | \text{cap} = 1'5) = 0$

$$\frac{P(\text{setosa})}{P(\text{versicolor})} = \frac{P(\text{cap} = 1'5 | \text{versicolor})}{P(\text{cap} = 1'5)} \frac{P(\text{versicolor})}{P(\text{cap} = 1'5)}$$

* 100 Ejemplos.
50 por clase

$$= \frac{15/50 \cdot 50/150}{P(\text{cap} = 1'5)} = \underline{\underline{0'85}}$$

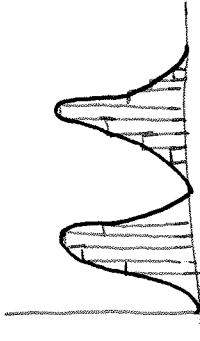
$$P(\text{virginica} | \text{cap} = 1'5) = \frac{3/50 \cdot 50/150}{P(\text{cap} = 1'5)} = 0'15$$

* Suponemos que la variable aleatoria α sigue una normal de media μ y varianza σ^2 .

Dada una muestra $\{x_1, x_2, \dots, x_n\}$ la verosimilitud viene dada por

$$P(x_1, x_2, \dots, x_n | \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

Objetivo: Hallar la media μ y la varianza para esta muestra.



* ver que gaussiana
se acerca más
a los datos.

Simplificando la fórmula aplicando el logaritmo en ambos lados.

$$\begin{aligned} \ln P(x_1, x_2, \dots, x_n | \mu, \sigma^2) &= \sum_{i=1}^n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \right) \\ &= \sum_{i=1}^n \left(\ln \frac{1}{\sqrt{2\pi\sigma^2}} + \ln e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \right) = \\ &= -n \cdot \ln \left(\sqrt{2\pi\sigma^2} \right) + \sum_{i=1}^n -\frac{(x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

¿Qué valores de μ y σ^2 maximizan la verosimilitud de la muestra?

$$\frac{\sigma^2}{\sigma^2}$$

$$\mathcal{L}(\mu, \sigma^2 | x_1, x_2, \dots, x_n | \mu, \sigma^2) = n \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \frac{\sigma}{2} (2\pi\sigma^2)^{-\frac{n}{2}}$$

$$\partial \sigma^2$$

$$+ \sum_{i=1}^n \frac{(x_i - \mu)^2}{2(\sigma^2)^2} = 0$$

para encontrar el máximo.

$$\frac{n \cdot 2\pi}{4\pi\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0$$

$$n + \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 = 0$$

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

← se demuestra derivando la ecuación principal respecto a μ e igualando a cero para maximizar.

ap

	setosa	versicolor	virginica
μ	0'246	1'326	2'026
σ^2	0'0111	0'0391	0'0754

$$P(\text{set} | \text{ap}=1^{15}) = \frac{P(\text{ap}=1^{15} | \text{set}) P(\text{set})}{P(\text{ap}=1^{15})} = \frac{\frac{1}{\sqrt{2\pi\sigma_{\text{set}}^2}} e^{-\frac{(1^{15}-\mu_{\text{set}})^2}{2\sigma_{\text{set}}^2}}}{P(\text{ap}=1^{15})}$$

$$\text{ap} = 1^{15}$$

Ejemplo 2.

9 octubre 2013

$$fs = 6^{13}$$

$$ap = 1^{16}$$

$$p(\dots | vir) \cdot p(vir) = 0^{124}$$

$$p(\dots | vir) \cdot p(vir) = 0^{157}$$

$$p(\dots | \dots) = 0$$

* Nodos gráficos (redes de Bayes)

Necesitamos la regla de la cadena: Aplicación de la regla del producto n veces.

Considerando las variables aleatorias e, c, p, d :

$$\begin{aligned} p(e, c, p, d) &= p(e|c, p, d) \cdot p(c|p, d) \cdot p(p|d) \\ &= p(e|c) \cdot p(c|p) \cdot p(p|d) \\ &= p(e|p, d) \cdot p(c|p, d) \cdot p(p|d) \end{aligned}$$

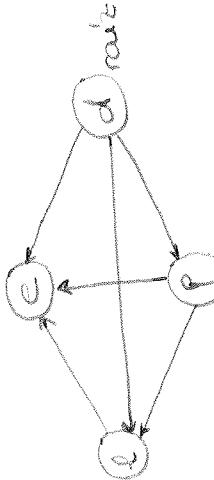
Representación gráfica
(mediante grafo acíclico dirigido)

General:

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i | \text{pa}_i)$$

pa_i = conjunto de los padres de la variable x_i .

Si x_i no tiene padres
 $p(x_i | \text{pa}_i) = p(x_i)$

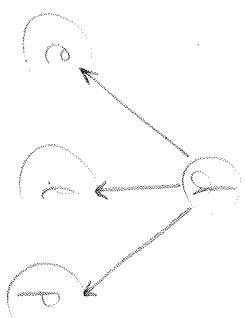


Nota: $p(d|e, c, p) = \frac{p(e, c, p, d)}{p(e, c, p)} = \frac{p(e|c, p, d) \cdot p(c|p, d) \cdot p(p|d)}{p(e|c, p)}$

NB $\Rightarrow p(e, c | p, d) = p(e|c, p, d) \cdot p(c|p, d) \cdot p(p|d)$

$$= p(e|d) \cdot p(c|d) \cdot p(p|d) \cdot p(d)$$

Por Naïve Bayes los nodos solo dependen de la clase.



- Ejemplos de los anteriores

$$\text{calcular: } p(d|a,e,p) = \frac{p(a,e,p,d)}{p(a,e,p)}$$

'd' depende de 'e' y 'd'

$$= \frac{p(a|d)p(e|d)p(p|d)p(d)}{p(a|e)p(e|p)}$$

$p(a|e,p)$

Ahora podemos asignar valores a las variables

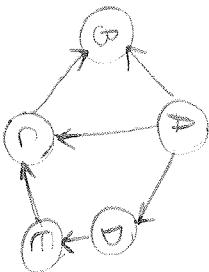
$D \mid e: \text{joven}, p = \text{normal}, a = s_n, e = j, p = n$ // $H = d \in \{n, d, b\}$

$$d = \text{no} \rightarrow p(d=n \mid a=s_n, e=j, p=n) = \frac{\frac{2}{4} \cdot \frac{4}{15} \cdot \frac{3}{15}}{p(\dots)} \cdot \frac{15}{24} = \frac{1}{160}$$

$$d = \text{duro} \rightarrow p(d=d \mid e=j, p=n, a=s_n) = \frac{\frac{3}{2} \cdot \frac{2}{4} \cdot \frac{4}{15} \cdot \frac{4}{15}}{p(\dots)} = \frac{1}{160}$$

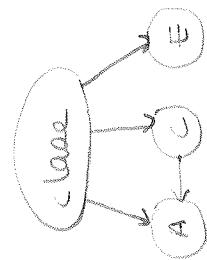
Ejemplo : calcular la verosimilitud de B, C, D y E dado A

$$p(b|a,c) \cdot p(c|a,e) \cdot p(d|a) \cdot p(e|d)$$



Ejemplo:

Tenemos $A \rightarrow C = S$ $C = E = \emptyset$
¿Clase más probable?



A	B	C	D	E	clase
1	0	1	0	0	A
1	1	0	0	1	A
1	1	0	1	0	S
0	1	1	1	1	S
0	1	1	0	1	A
0	0	0	1	0	A
1	0	1	0	0	A
0	1	0	1	0	A
0	0	0	0	1	S
0	0	0	1	1	A
1	0	0	0	1	A
1	1	0	0	1	S

$$P(A, C, D | \text{clase}) = \frac{P(\text{clase}, \text{clase})}{P(\text{clase})} = \frac{P(\text{clase}, \text{clase}) P(\text{clase})}{P(\text{clase})} = P(\text{clase})$$

Solución: 67% Clase A

33% Clase S

11 octubre 2013

vecinos próximos ($k - NN$)

Hasta

ahora la prob de la verosimilitud
• discretos: frecuencias

$$P(X = x | h_i) = \frac{\# \text{casos con } x = v_i \text{ y } h_i}{\# \text{casos de } h_i}$$

• cuantitativos:

- discretizar, generar histogramas y usar estimación no paramétrica
- estimar la densidad de prob. (con gaussiana)

- estimación de densidad

~~#frecuencias~~

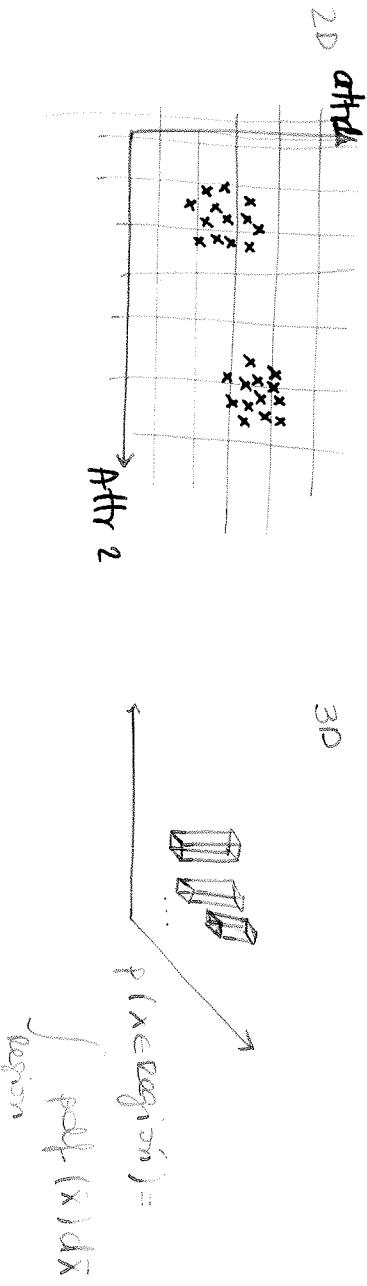
función prob. = pdf (En nuestro caso pdf = gaussiana paralela de densidad)

función prob. = pdf (En nuestro caso pdf = gaussiana paralela de densidad)

$$P(1^{14} < X < 1^{15}) = \int_{1^{14}}^{1^{15}} \text{pdf}(x) dx$$

* No siempre se puede aplicar una gaussiana.

Valos a generalizar la estimación por histogramas a D-dimensiones.



Estimación de:

$$P(\bar{x} \in \text{Región}) = \int_{\text{Región}} \text{pdf}(\bar{x}) d\bar{x}$$

1: como histogramas con frecuencias.

Sean k_R el número de puntos dentro de la región R y N el número total de puntos,

$P(x \in R) = \frac{k_R}{N}$ → Pode de ser grande para que la aproximación sea válida y espacio tiene que estar bien cubierto de puntos.

2: Si ponemos R pequeño, podemos suponer que $\text{pdf}(\bar{x})$ es constante en dicha región y

$$P(\bar{x} \in R) = \underbrace{\text{pdf}(\bar{x}_R)}_{\text{altura}} \cdot \underbrace{\frac{1}{k}}_{\text{Base o volumen}} = \text{pdf}(\bar{x}_R) \cdot \frac{V_R}{V}$$

volumen depende de la dimensión

* Igualando t : y^2 :

$$p(\bar{x}_{EP}) = \frac{k_e}{N} = p_{\bar{f}}(\bar{x}_e) V_e \quad * \text{ con } N \text{ suficiente grande y } V_e \text{ suficiente pequeño}$$

$$p_{\bar{f}}(\bar{x}_e) = \frac{k_e}{N V_e}$$

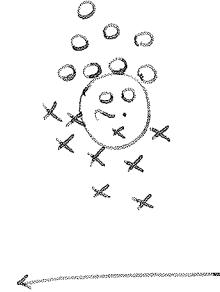
- FORMAS DE USAR LA DENSIDAD

- Fijando k_e (número de puntos en \bar{e}) y obteniendo el V_e necesario para que sea k_e puntos
- vecinos próximos ($k - NN$) -

• Fijando V_e y calculando k_e .

- MÉTODOS DE NÚCLEOS (k-near) -

Ejemplo: Fijamos k_e



x : clase 1

o : clase 2

$$k_e = 4 \quad ; \quad N_1 = 8 \quad ; \quad N_2 = 7$$

$$N = 15 \quad ; \quad ? : \text{punto de consulta.}$$

16 octubre 2013

$$p(\bar{x}_e) = \frac{k_e}{N V_e}$$

→ estimación de densidad de prob.

- verosimilitud
- $p(\bar{x}_e | c) = \frac{k_e}{N_c V_e}$

• Evidencia

$$p(x) = \frac{k}{N V_e}$$

• Prob. a priori

$$P(c) = \frac{N_c}{N}$$

Si aplicando Bayes a $P(Cc|\bar{x})$ obtenemos la prob. a posteriori.

$$P(Cc|\bar{x}) = \frac{P(\bar{x}|Cc) P(Cc)}{P(\bar{x})} = \frac{\frac{k_c}{N_{\text{total}}}}{\frac{k}{N_{\text{total}}}} = \frac{k_c}{k}$$

$$\boxed{P(Cc|\bar{x}) = \frac{k_c}{k}}$$

... aplicando la fórmula al ejemplo...

$$P(C) = \frac{3}{4} \rightarrow \text{con } k = 4$$

$$P(\bar{x}) = \frac{1}{4}$$

Regla de clasificación k-nn

Def: la clase más común dentro de los k vecinos más próximos se pueete a clasificar

Algoritmo k-nn

- Extrayéndolo
 - No hay, se guardan todos los ejemplos.

as \uparrow
m \uparrow
 \uparrow
 \uparrow

• clasificación (\bar{x})
 \rightarrow calcular las distancias al resto de
 ejemplos con métricas.

\rightarrow seleccionar los k más próximos

\rightarrow Devolver el más común.

as
(con)
 \uparrow

\uparrow
 \uparrow
 \uparrow

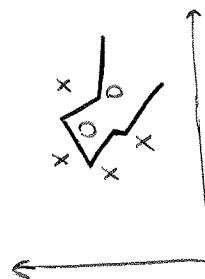
\rightarrow ap

Solución basada a la única: Distancia euclídea
y normalizar cada attr para que tenga media 0 y
variancia 1.

Selección del k óptimo.

- Calcular la cantidad de distancias entre todos los puntos de entrenamiento
- para cada pto. clasificar probando todos los k y comparar con la clase real.
- Resolver k con menor error.

Frontera de clasificación.



Polygono de threshold o
diagrama de vonóni.

- * Otros problemas de k - NN.
 - Existencia de attr. irrelevantes.
- Solte 1
 - En memoria
 - en tiempo de clasificación
- * Selección de prototipos: Buscar los subconjuntos del original T.
- Algoritmo: CNN (condensed NN)
 - Dividirlos s con un ejemplo por clase al azar.
 - do l para cada ejemplo x en T
 - si la clase asignada a x por s es incorrecta
 - $S = S \cup \bar{x}$
- while (cambies)

Para attr. discretos: la distancia es 1 a los que sean distintos

$$\text{dist}(\bar{x}_1, \bar{x}_2) = \sum_{i=1}^{n_{\text{attr}}} T(\bar{x}_1[i] + \bar{x}_2[i])$$

$$T(\text{true}) = 1$$

$$T(\text{false}) = 0$$

18 octubre '13

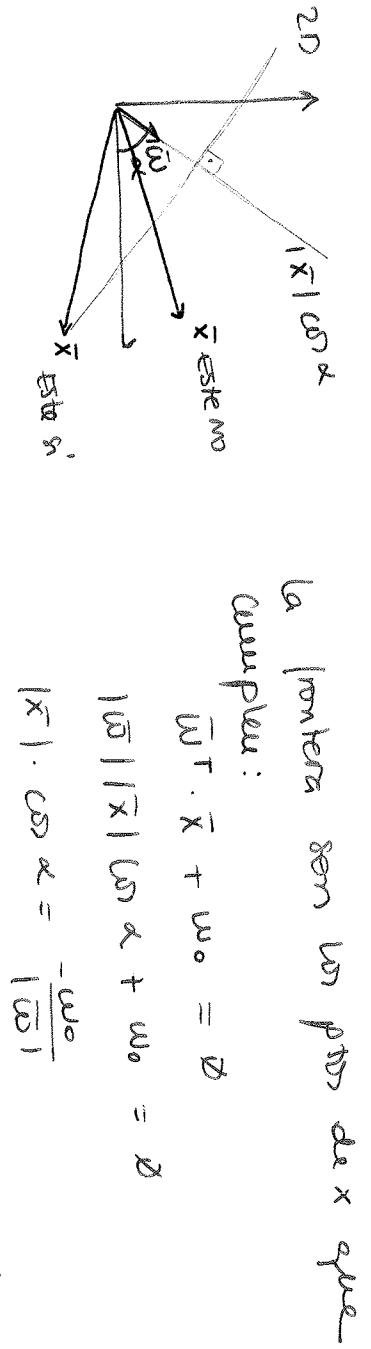
Clasificadores lineales

Clasificadores cuya frontera de decisión es un plano.

Sea h un clasificador lineal:

$$h(\bar{x}) = \begin{cases} c_1 & \text{si } \bar{w}^\top \cdot \bar{x} + w_0 \geq 0 \\ c_2 & \text{si } \bar{w}^\top \cdot \bar{x} + w_0 < 0 \end{cases}$$

w_0 es una cte. \bar{w} = vector de D-dimensiones



23 octubre '13

FUNCION SIGMOIDAL

Considerando un problema de 2 clases C_1 y C_2 (a prob. a posteriori es:

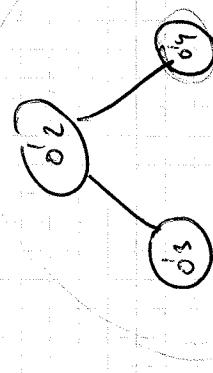
$$P(c_1 | \bar{x}) = \frac{P(\bar{x} | c_1) P(c_1)}{P(\bar{x})} = \frac{P(\bar{x} | c_1) P(c_1)}{P(\bar{x} | c_1) P(c_1) + P(\bar{x} | c_2) P(c_2)}$$

Inicio



$$X_1 = \frac{X_1 - \mu_1}{\sigma_1}$$

$$K=3$$



Selección del K óptimo mediante validación en train:

K-optimo()

validación

Se calcula distancia entre todos los pares de puntos

Para todo ejemplo en train

leave

one

out

Se ordenan el resto de ejemplos por distancias

Se hacen tantas clasificaciones como valores de K se estén probando.

Se calcula el error para cada K y devolvemos el K con menor error.

Más inconvenientes

- Existe una de adiciones irrelevantes \rightarrow produce distancias que no son relevantes

- Coste \rightarrow para cada ejemplo clacular long K calcular distancias como ejemplos en train.

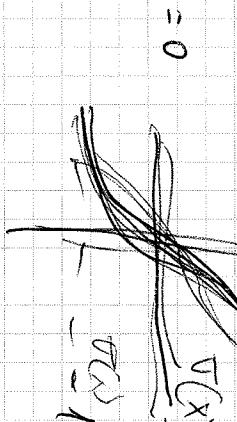
Clasificador lineal

vector perpendicular a la recta

$$h(\bar{x}) = \begin{cases} c_1 & \text{si } \bar{w}^T \bar{x} + w_0 > 0 \\ c_2 & \text{si } \bar{w}^T \bar{x} + w_0 \leq 0 \end{cases}$$

$$\text{frontera} \Rightarrow \bar{w}^T \bar{x} + w_0 = 0$$

$$|\bar{w}^T| / |\bar{w}| \cos \alpha = -w_0 / |\bar{w}|$$

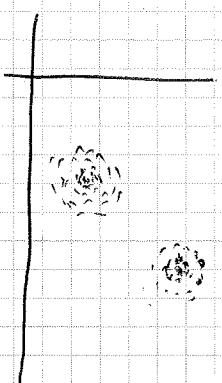
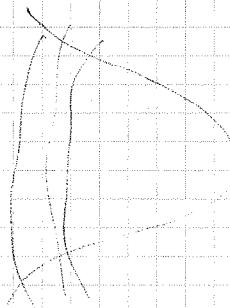
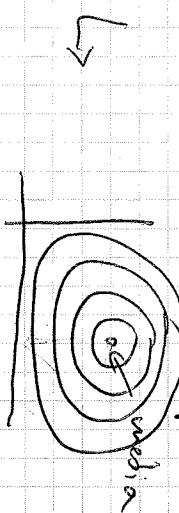


Vamos a ver como surgen de forma "natural" haciendo suposiciones sencillas

Sobre los datos

Máxima de covarianzas \Rightarrow igualdad

\hookrightarrow Los puntos están desparados por igual

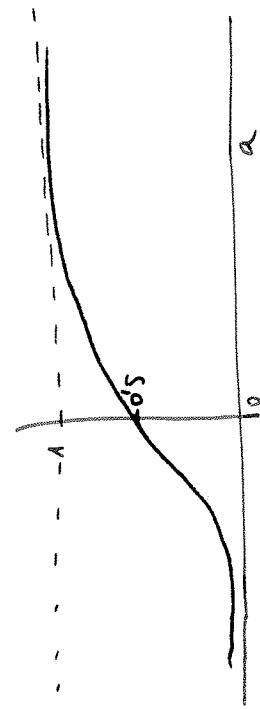


... dividimos el denominador entre $P(\bar{x}|c_1)P(c_1)$

$$P(c_1|\bar{x}) = \frac{1}{1 + \frac{P(\bar{x}|c_2)P(c_2)}{P(\bar{x}|c_1)P(c_1)}} = \frac{1}{1 + e^{-\alpha}} = \sigma(\alpha)$$

$$\text{con } \alpha = \ln \frac{P(\bar{x}|c_1)P(c_1)}{P(\bar{x}|c_2)P(c_2)}$$

función sigmoidal o de activación.



Decisión:

$$\begin{cases} \text{Si } P(c_1|\bar{x}) > 0.5 \rightarrow c_1 \\ \text{Si no} \qquad \qquad \qquad \rightarrow c_2 \\ \text{Si } \alpha > 0 \qquad \qquad \rightarrow c_1 \\ \text{Si no} \qquad \qquad \qquad \rightarrow c_2 \end{cases}$$

Suponemos que la verosimilitud sigue una distribución normal $N(\bar{\mu}_k, \Sigma_k)$ dada la clase k.

$$P(\bar{x}|c_k) = N(\bar{\mu}_k, \Sigma_k) = \frac{1}{(2\pi)^{D/2} |\Sigma_k|^{1/2}} \exp \frac{1}{2} (\bar{x} - \bar{\mu}_k)^T \Sigma_k^{-1} (\bar{x} - \bar{\mu}_k)$$

vector de medianas de covarianzas

Caso 1: Suponemos dos clases $\Sigma_k = \text{Identidad}$.

$$\alpha = \ln \frac{P(\bar{x}|c_1)P(c_1)}{P(\bar{x}|c_2)P(c_2)} = \ln \left[\exp \left\{ \frac{(\bar{x} - \bar{\mu}_1)^2}{2} - \frac{(\bar{x} - \bar{\mu}_2)^2}{2} \right\} \frac{P(c_1)}{P(c_2)} \right] =$$

$$= \frac{(\bar{x} - \bar{\mu}_1)^2}{2} - \frac{(\bar{x} - \bar{\mu}_2)^2}{2} + \ln \frac{P(c_1)}{P(c_2)} \rightarrow \alpha \Rightarrow c_1$$

Caso 4.1. : Si los prob. a priori son iguales $P(C_1) = P(C_2)$

$$\rightarrow \frac{(\bar{x} - \bar{\mu}_2)^2}{2} > \frac{(\bar{x} - \bar{\mu}_1)^2}{2}$$

$$\therefore \bar{x} - (\bar{\mu}_2)^2 > (\bar{x} - \bar{\mu}_1)^2 \rightarrow C_1$$

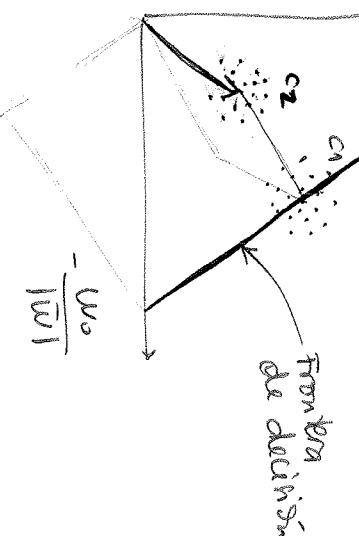
¿Qué frontera tenemos?

$$P(C_1 | \bar{x}) = P(C_2 | \bar{x}) = 0.5$$

$$\alpha = 0$$

$$\frac{(\bar{x} - \bar{\mu}_2)^2}{2} - \frac{(\bar{x} - \bar{\mu}_1)^2}{2} = \frac{\bar{\mu}_1^2 + \bar{x}^2 - 2\bar{x}\bar{\mu}_1}{2} + \ln \frac{P(C_1)}{P(C_2)} = 0$$

$$(\bar{\mu}_1 - \bar{\mu}_2)^\top \bar{x} + \frac{1}{2} (\bar{\mu}_2^2 - \bar{\mu}_1^2) + \ln \frac{P(C_1)}{P(C_2)} = 0$$



$$\bar{w}^\top \cdot \bar{x} + w_0 = 0$$

$$\bar{w} = \bar{\mu}_1 - \bar{\mu}_2$$

$$w_0 = \frac{1}{2} (\bar{\mu}_2^2 - \bar{\mu}_1^2) + \ln \frac{P(C_1)}{P(C_2)}$$

¿Qué pasa si $P(C_1) > P(C_2)$? ¿Hacia dónde se mueve el hipoplano?

caso 2: Separaciones

$$= 2 \text{ clases} = \sum_1 = \sum_2$$

$$\begin{aligned} a = \ln \frac{P(\bar{x}_n | C_1) P(C_1)}{P(\bar{x}_n | C_2) P(C_2)} &= \ln \left[\exp \left\{ \frac{-1}{2} (\bar{x} - \bar{\mu}_1) \Sigma^{-1} (\bar{x} - \bar{\mu}_1)^\top + \right. \right. \\ &\quad \left. \left. + \frac{1}{2} (\bar{x} - \bar{\mu}_2) \Sigma^{-1} (\bar{x} - \bar{\mu}_2)^\top \cdot \frac{P(C_1)}{P(C_2)} \right] = \right. \end{aligned}$$

$$\begin{aligned}
&= -\frac{1}{2} (\bar{x} - \mu_1) \sum^{-1} (\bar{x} - \mu_1) + \frac{1}{2} (\bar{x} - \mu_2) \sum^{-1} (\bar{x} - \mu_2) + \ln \frac{p(c_1)}{p(c_2)} = \\
&= -\frac{1}{2} (\bar{x} \sum^{-1} \bar{x} - \mu_1 \sum^{-1} \bar{x} - \bar{x} \sum^{-1} \bar{\mu}_1 + \bar{\mu}_1 \sum^{-1} \bar{\mu}_1) + \\
&\quad + \frac{1}{2} (\bar{x} \sum^{-1} \bar{x} - \mu_2 \sum^{-1} \bar{x} - \bar{x} \sum^{-1} \bar{\mu}_2 + \bar{\mu}_2 \sum^{-1} \bar{\mu}_2) + \ln \frac{p(c_1)}{p(c_2)} = \\
&= \frac{1}{2} \left((\bar{\mu}_1 - \bar{\mu}_2) \sum^{-1} + (\sum^{-1} (\bar{\mu}_1 - \bar{\mu}_2))^T \right) \bar{x} + \frac{1}{2} \left(\bar{\mu}_1 \sum^{-1} \bar{\mu}_1 + \bar{\mu}_2 \sum^{-1} \bar{\mu}_2 \right) + \\
&\quad + \ln \frac{p(c_1)}{p(c_2)} \\
&\rightarrow \bar{w} = \sum^{-1} (\bar{\mu}_1 - \bar{\mu}_2) ; w_0 = -\frac{1}{2} \bar{\mu}_1 \sum^{-1} \bar{\mu}_1 + \frac{1}{2} \bar{\mu}_2 \sum^{-1} \bar{\mu}_2 + \ln \frac{p(c_1)}{p(c_2)}
\end{aligned}$$

Que las matrices de covarianza sean iguales, quiere decir que los nubles de puestor van a tener la misma forma

$$P(c_1 | \bar{x}) = \bar{v}(c_1) = \bar{v}(\bar{w}^T \bar{x} + w_0)$$

$$\ln \frac{p(\bar{x} | c_1) p(c_1)}{p(\bar{x} | c_2) p(c_2)} = \bar{w}^T \bar{x} + w_0 \xrightarrow{\text{bajo ciertas suposiciones es una recta.}}$$

$$[\text{si } P(c_1 | \bar{x}) > 0.5] \equiv [\text{si } \alpha > 0] \equiv [\text{si } \bar{w}^T \bar{x} + w_0 > \rho]$$

25 octubre '13

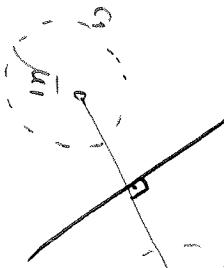
REGRESIÓN LOGÍSTICA (No es regresión!)

Nuevos visto que bajo ciertas condiciones $\begin{cases} p(\bar{x} | c_1) = N(\bar{\mu}_1, \Sigma) \\ p(\bar{x} | c_2) = N(\bar{\mu}_2, \Sigma) \end{cases}$ entonces la prob. a posteriori de c_1 es $P(c_1 | \bar{x}) = \bar{v}(\bar{w}^T \bar{x} + w_0)$

$$\begin{aligned}
\text{con } \bar{w}^T &= \sum^{-1} (\bar{\mu}_1 - \bar{\mu}_2) \\
w_0 &= -\frac{1}{2} \bar{\mu}_1^T \sum^{-1} \bar{\mu}_1 + \frac{1}{2} \bar{\mu}_2^T \sum^{-1} \bar{\mu}_2 + \ln \frac{p(c_1)}{p(c_2)}
\end{aligned}$$

1. Técnicas

$\Sigma_1 = \Sigma_2 = \mathbb{I}$ Nube de
punto con
 μ_1, μ_2 : mayor prob. de
punto en el otro.



L

OPI: Estimar $\hat{\mu}_1, \hat{\mu}_2$ y Σ por MV para D-dimensiones

$$\hat{\mu} \text{ de parámetro: } \hat{\mu} = \bar{x} + \frac{D(D+1)}{2} \Sigma$$

$$\frac{\hat{\mu}_1}{\hat{\mu}_2}$$

$$\Sigma \text{ Simplificando notación:}$$

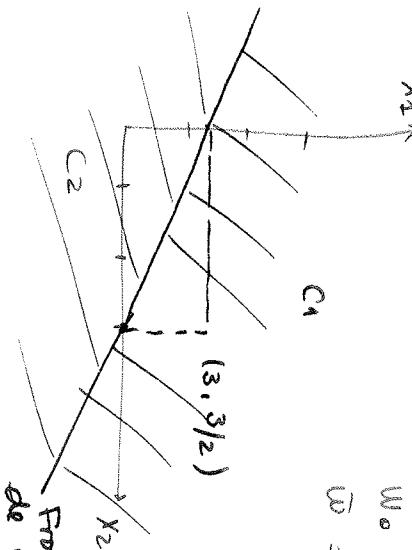
$$\bar{\omega} \rightarrow (w_0, w_1, w_2, \dots, w_D)$$

OPI2: estimar $\bar{\omega}$ y w_0 por MV

$\bar{\omega}$ + 1 parámetros

$$\Rightarrow P(C_1 | \bar{x}) = \mathcal{T}(\bar{\omega} + \bar{x})$$

→ ejemplo:



Fronteza
de decisión.

i Prob. de que $(3, 3/2)$ sea C_1 ?

$$P(C_1 | \bar{x}) = \mathcal{T}(\underbrace{\bar{\omega}^T \bar{x} + w_0}_{a}) = \mathcal{T}(1) = \frac{1}{1+e^{-1}} = 0.73$$

$$a = \frac{1}{3} \cdot 3 + \frac{2}{3} \cdot \frac{3}{2} - 1 = 1$$

$$x = (0, 0) \rightarrow P(C_1 | \bar{x}) = \mathcal{T}(-1) = \frac{1}{1+e^1} = 0.27.$$

Tenemos un conjunto de entrenamiento

$$D = \{ \begin{cases} 1 & \text{si } \bar{x}_i \in C_1 \\ 0 & \text{si } \bar{x}_i \in C_2 \end{cases} \quad i = 1, \dots, N \}$$

donde $t_i \begin{cases} 1 & \text{si } \bar{x}_i \in C_1 \\ 0 & \text{si } \bar{x}_i \in C_2 \end{cases}$

En reg. logística ...

$$P(H|D) = \frac{P(D|H)P(H)}{P(D)}$$

$$H = \bar{\omega}$$

$$\begin{aligned} D &= t_1, \dots, t_N \\ T &= \bar{x}_1, \dots, \bar{x}_N \end{aligned}$$

y con verosimilitud

$$\begin{aligned} P(t_1, \dots, t_N | \bar{\omega}, \bar{x}_1, \dots, \bar{x}_N) &= \prod_{i=1}^N P(t_i | \bar{\omega}, \bar{x}_i) = \\ &= \prod_{i=1}^N t_i (1 - \bar{\omega})^{1-t_i} \text{ aplicando la forma simplificada} \end{aligned}$$

$$\begin{aligned} \ln P(t_1, \dots, t_N | \bar{\omega}, \bar{x}_1, \dots, \bar{x}_N) &= -\sum_{i=1}^N t_i \ln \bar{\omega} - \\ &\quad - \sum_{i=1}^N (1 - t_i) \ln (1 - \bar{\omega}) \end{aligned}$$

Optimizamos ...

$$\begin{aligned} \frac{\partial}{\partial \bar{\omega}} \left(-\ln P(t_1, \dots, t_N | \bar{\omega}, \bar{x}_1, \dots, \bar{x}_N) \right) &= 20 \text{ oct '13} \\ \frac{\partial E}{\partial \bar{\omega}} &= \varnothing; \quad \frac{\partial E}{\partial \bar{\omega}} = \left(-\sum_{i=1}^N t_i \frac{1}{\bar{\omega}^{t_i}} + \sum_{i=1}^N (1 - t_i) \frac{1}{1 - \bar{\omega}^{t_i}} \right) \frac{\partial \bar{\omega}}{\partial \bar{\omega}} = \\ &= \left(-\sum_{i=1}^N t_i (1 - \bar{\omega})^{1-t_i} + \sum_{i=1}^N (1 - t_i) (\bar{\omega})^{t_i} \right) \bar{x}_i = \sum_{i=1}^N (t_i + \bar{\omega}^{t_i} - \bar{\omega}^{t_i}) \bar{x}_i = \end{aligned}$$

$$\begin{aligned} &= \sum_{i=1}^N (\bar{\omega}^{t_i} - t_i) \bar{x}_i = \sum_{i=1}^N (\bar{\omega}^{t_i} \bar{x}_i - t_i) \bar{x}_i = 0 \\ \frac{\partial \bar{\omega}}{\partial \bar{\omega}} &= \frac{\partial}{\partial \bar{\omega}} \frac{1}{1 + e^{-\bar{\omega}^T \bar{x}_i}} = \frac{+e^{-\bar{\omega}^T \bar{x}_i}}{(1 + e^{-\bar{\omega}^T \bar{x}_i})^2} = \frac{1}{1 + e^{-\bar{\omega}^T \bar{x}_i}} \cdot \frac{-e^{-\bar{\omega}^T \bar{x}_i}}{1 + e^{-\bar{\omega}^T \bar{x}_i}} \\ &= \bar{\omega}^T \bar{x}_i \end{aligned}$$

$$= \bar{\omega}^T \bar{x}_i$$

— Para un ejemplo:

$$\frac{\partial E_i}{\partial \bar{w}} = \left(J - (\bar{w}^T \bar{x}_i) - t_i \right) \bar{x}_i$$

para aumentar la verosimilitud del ejemplo x_i hay que mover la recta \tilde{w} en sentido opuesto al gradiente $(\tilde{y}_i - \hat{y}_i)x_i$ y proporcional a una cte. de aprendizaje η .

$$\bar{W}_{th} \leftarrow \bar{W}_t - \eta (\bar{T}_i - t_i) \bar{x}_{\text{initial}}$$

Algoritmo iterativo

reg-logistica (η , n\'opas, datos_train)

las dimensiones

6
Determinant

adminbutton + 1 =

卷之三

Ejemplo:

$x_0 \quad x_1 \quad x_2$

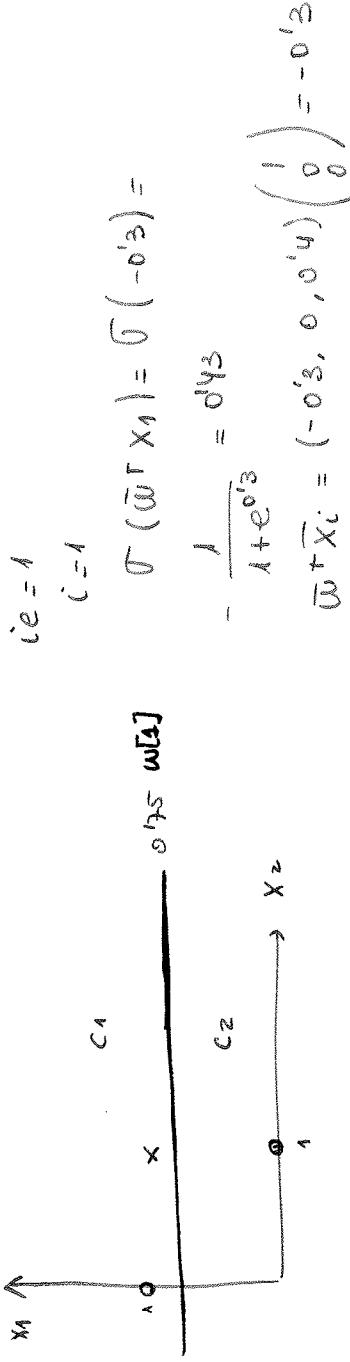
一〇〇

一
八
〇

一〇一

二

perseverance, determination, and
high moral standards.



$$t=0 \rightarrow c_2$$

$$t=1 \rightarrow c_1$$

$$\bar{w}^T x_i = \begin{pmatrix} -0'3 & 0'4 & 0'4 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = -0'3$$

Ahora voy a actualizar el vector \bar{w} : $\bar{w} = \begin{pmatrix} -0'3 \\ 0 \\ 0'4 \end{pmatrix} - t \cdot (0'43 - 0) \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} =$

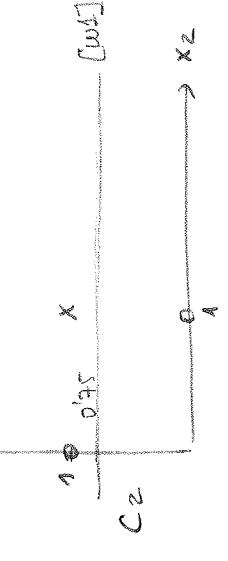
$$= \begin{pmatrix} -0'73 \\ 0 \\ 0'4 \end{pmatrix}$$

Sigue la misma recta fronteira o
al nuevo vector es igual a:

$$-0'73 + x_2 \cdot 0'4 = \varnothing$$

$$x_2 = \frac{-0'73}{0'4} = 1'8$$

$$[w2]$$



Entonces ...

$$ie = 1$$

$$i=2 \quad \bar{w}^T (\bar{w}^T x_i) = \bar{w}^T (-0'73) = \frac{1}{1+e^{-0'73}} = 0'335$$

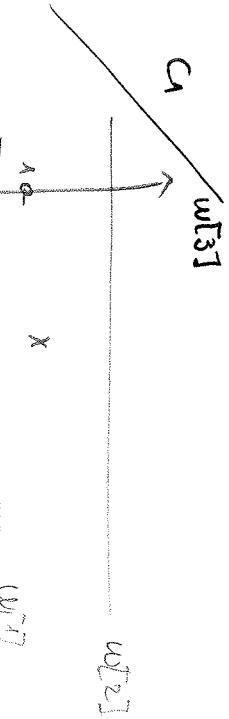
$$\bar{w}^T x_2 = (-0'73, 0, 0'4) \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \frac{-0'73}{1+e^{-0'73}} =$$

Redefinimos el vector \bar{w}

$$\bar{w} = \begin{pmatrix} -0'73 \\ 0 \\ 0'4 \end{pmatrix} - 1 \cdot (0'335 - 0) \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} -0'73 \\ 0 \\ 0'4 \end{pmatrix} - \begin{pmatrix} 0'335 \\ 0'335 \\ 0'335 \end{pmatrix} = \begin{pmatrix} -1'05 \\ -0'33 \\ 0'4 \end{pmatrix}$$

$$-1'05 - 0'335 x_1 + 0'4 x_2 = \varnothing$$

$$x_1 = \varnothing; x_2 = \frac{1'05}{0'4} = 2'6 \quad // \quad x_2 = \varnothing; x_1 = \frac{-1'05}{0'33} = -3$$



Iteration

$$ie = 1$$

$$i = 3$$

$$\mathcal{T}(\bar{w}^\top \cdot \pi_3) = \mathcal{T}(-0'05) = 0'34 \rightarrow \bar{w} = \begin{pmatrix} -1'39 \\ -0'33 \\ 0'06 \end{pmatrix} \rightarrow$$

$$\rightarrow -1'39 - 0'33 x_1 + 0'06 x_2 = 0$$

$$x_1 = 0 \rightarrow x_2 =$$

$$x_2 = 0 \rightarrow x_1 = -\frac{1'39}{0'33}$$

Iteration

$$ie = 1$$

$$\lambda = 4 \quad \mathcal{T}(\bar{w}^\top \cdot \pi_4) = \mathcal{T}(-1'66) = 0'16$$

$$\bar{w}^\top \pi_4 = (-1'39, -0'33, 0'06) \begin{pmatrix} 1 \\ 1 \end{pmatrix} = -1'66$$

$$\bar{w} = \begin{pmatrix} -1'24 \\ -0'33 \\ 0'06 \end{pmatrix} - 1 (0'16 - 1) \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -0'55 \\ 0'5 \\ 0'06 \end{pmatrix}$$

$$-0'55 + 0'5 x_1 + 0'44 x_2 = 0$$

$$x_1 = 0 \rightarrow x_2 = \frac{0'55}{0'44}; \quad x_2 = 0 \rightarrow x_1 = 1'0$$

$$train 4 epochs: w = (-2'07 \quad 1'55 \quad 1'944)$$

$$" 12 " : w = (-3'68 \quad 2'72 \quad 2'82)$$

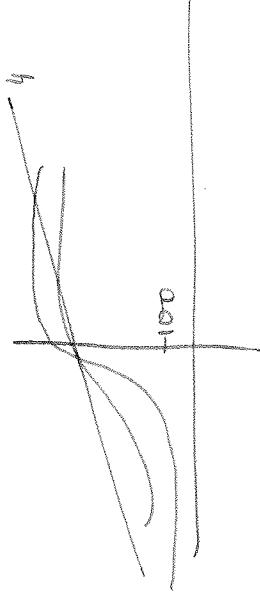
$$" 100 " : w = (-8'94 \quad 5'88 \quad 5'94)$$

$$P(c_1 | \bar{x}) = \nabla(\bar{w}^T \bar{x})$$

$$\begin{array}{c} X_0 \quad X_1 \quad X_2 \quad b \quad 4 \quad 12 \quad 100 \\ \hline 1 \quad 0 \quad 0 \quad 0 \quad 0'4 \quad 0'025 \quad 0'00013 \\ 1 \quad 1 \quad 0 \quad 0 \quad 0'37 \quad 0'23 \quad 0'045 \\ 1 \quad 0 \quad 1 \quad 0 \quad 0'47 \quad 0'30 \quad 0'047 \\ 1 \quad 1 \quad 1 \quad 1 \quad 0'81 \quad 0'84 \quad 0'95 \end{array}$$

$$\bar{w}^T \bar{x} = (-2'07 \ 1'557 \ 1'944) \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = -2'07$$

! Sobreaprendizaje!



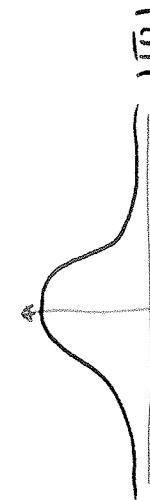
Reg. logística para MAP

Daremos obtener el máximo de: \rightarrow proporcionar a

$$P(\bar{w} | t_1, \dots, t_N, \bar{x}_1, \dots, \bar{x}_N) \propto \underbrace{\prod_{i=1}^N \sigma(t_i - \bar{w} \cdot \bar{x}_i)}_{P(\bar{w} \dots t_N | \bar{w} \cdot \bar{x}_1 \dots \bar{x}_N)}$$

Vamos a poner una gaussiana al mod. del vector

$$P(\bar{w}) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{\|\bar{w}\|^2}{2\sigma^2}}$$



Aplicando la

$$E = \ln P(\bar{w} | t_1, \dots, t_N, \bar{x}_1, \dots, \bar{x}_N, \bar{w}) \propto$$

$$\alpha - \sum_i^n t_i \ln \sigma_i - \sum_i^n (1 - t_i) \ln (1 - \sigma_i) + \frac{\|\bar{w}\|^2}{2\sigma^2}$$

$\sigma \neq \sigma_i$

↑
varianza
del módulo
de \bar{w} .

Definimos prob. a priori para \bar{w}

$$p(\bar{w}) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{|\bar{w}|^2}{2\sigma^2}}$$

la prob posterior

$$p(\bar{w} | t_1, \dots, t_n, \bar{x}_1, \dots, \bar{x}_n) \propto$$

6 Noviembre

$$E = \sum_{i=1}^N \epsilon_i = - \sum_{i=1}^N t_i \ln \bar{\pi}_i - \sum_{i=1}^N (1-t_i) \ln (1-\bar{\pi}_i) + \sum_{i=1}^N \frac{w^2}{2\sigma^2 N}$$

derivando...

$$\frac{\partial E}{\partial w} = (\bar{\pi}_i - t_i) \bar{x}_i + \frac{\bar{w}}{N\sigma^2} \rightarrow \text{Regla de actualización}$$

$$\bar{w} \leftarrow \bar{w} - \eta \left((\bar{\pi}_i - t_i) \bar{x}_i - \frac{\bar{w}}{N\sigma^2} \right)$$

Algoritmo : reg-logistica-map (y , epochs, Dato^D, σ^2)

* Generamos \bar{w} con valores $\in (-0'5, 0'5)$

* para ie = 1 \rightarrow epochs

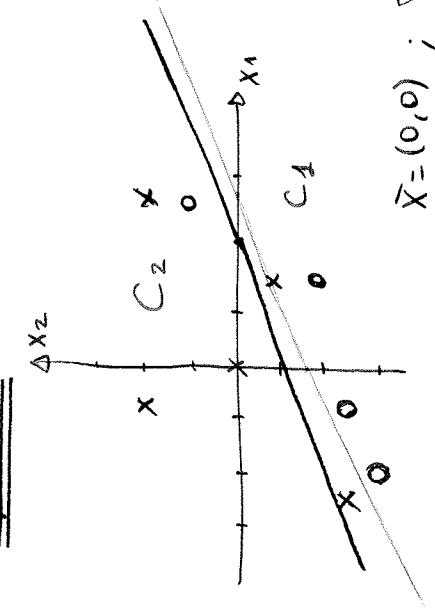
. Para i = 1 \rightarrow N

- se calcula $\bar{\pi}_i = \nabla (\bar{w}^\top \cdot \bar{x}) // \text{Prob de } \in C_1$
- se actualiza \bar{w}

$$\bar{w} = \bar{w} - \eta ((\bar{\pi}_i - t_i) \bar{x}_i - \frac{y}{N\sigma^2} \bar{w})$$

return.

Ejercicios



$$w = (-8 \quad 4 \quad -8)$$

$$\begin{cases} w_0 + w_1 x_1 + w_2 x_2 = 0 & y=2 \\ -8 + 4x_1 - 8x_2 = 0 & y=-1 \end{cases}$$

¿Qué clase en cada parte de la recta? Miraros

en el (0,0)

$$\bar{x} = (0,0); \quad \Gamma(-8 + 4 \cdot 0 - 8 \cdot 0) = \Gamma(-8) = \frac{1}{1+e^8} < 0'5$$

La prob. de ser de clase 1

es < 0'5, por lo que es de clase 2.

Asignar a 0 y una clase (1 ó 2) minimizando el error.

$$\begin{cases} 0 \rightarrow c_1 \\ x \rightarrow c_2 \end{cases} \quad \text{error} = \frac{3}{9}$$

Asignación con error menor.

Actualizar w usando reg-logística - MAP para $\hat{x} = (-2'5, -2'5)$

$$\begin{aligned} \gamma &= 0'5, \quad \sigma^2 = 1 \quad y \quad N = 10 \\ \bar{w} &= \bar{w} - \eta (\bar{v}_i - \bar{v}_i) \bar{x} - \frac{\eta}{N\sigma^2} \bar{w} = \begin{pmatrix} -8 \\ 4 \\ -8 \end{pmatrix} - 0'5 \begin{pmatrix} 0'88 - 0 \\ -2'5 \\ -2'5 \end{pmatrix} - 0'05 \begin{pmatrix} 1 \\ -2'5 \\ -2'5 \end{pmatrix} \\ \bar{v}_i &= \Gamma(\bar{w}^\top \cdot \bar{x}) = \Gamma(z) = \frac{1}{1+e^{-z}} = 0'88 \end{aligned}$$

$$\Rightarrow \bar{w}^\top \bar{x} = (-8 \quad 4 \quad -8) \begin{pmatrix} 1 \\ -2'5 \\ -2'5 \end{pmatrix} = -8 - 10 + 20 = 2$$

recta: $-8'84 + 3'78x_1 - 6'5x_2 = 0$.

$$x_1 = 0 \rightarrow x_2 = -\frac{8'84}{6'5}$$

$$x_2 = 0 \rightarrow x_1 = \frac{8'84}{3'78}$$

* 2 classes con distr. normal en 4D

$$\Sigma_1 = \Sigma_2 = \mathbb{I} \quad \mu_1 = (1, 1, 1, 1) \quad \mu_2 = (-1, -1, -1, -1)$$

• Parámetros óptimos de la recta dada por Bayes?

$$P(C_1) = P(C_2)$$

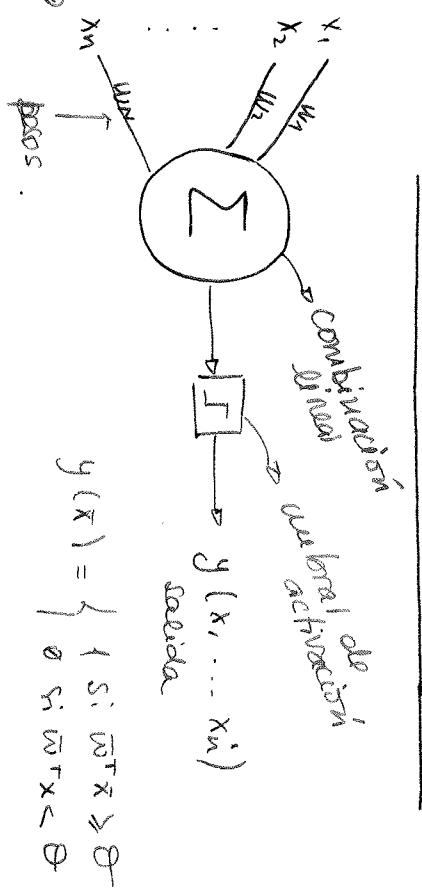
$$\bar{w} = \bar{\mu}_1 - \bar{\mu}_2$$

$$w_0 = \frac{1}{2} \left(\bar{\mu}_2^2 - \bar{\mu}_1^2 \right) + \ln \frac{P(C_1)}{P(C_2)}$$

$$\bar{w} = (1 \ 1 \ 1 \ 1) - (-1 \ -1 \ -1 \ -1) = (2 \ 2 \ 2 \ 2)$$

$$w_0 = \frac{1}{2} (4 - 4) + \ln 1 = 0$$

REDES NEURONALES



$$y(\bar{x}) = \begin{cases} 1 & \text{si } \bar{w}^T \bar{x} > \theta \\ 0 & \text{si } \bar{w}^T \bar{x} < \theta \end{cases}$$

atm.

$$\text{AND} \quad w_1 = w_2 = 1 \quad \theta = 1.5$$

x_1	x_2	t	$x_1 w_1 + x_2 w_2$	$y(\bar{x})$
0	0	0	0	0
0	1	0	1 > 0 → 0	0
1	0	0	1 > 0 → 0	0
1	1	1	2 > 0 → 1	1

* Integración de un brod

$$y(x_1 \dots x_n) = \begin{cases} 1 & w_0 + w_1 x_1 + \dots + w_n x_n \geq 0 \\ 0 & \text{"} \end{cases}$$

* Función escalon o de Heavide



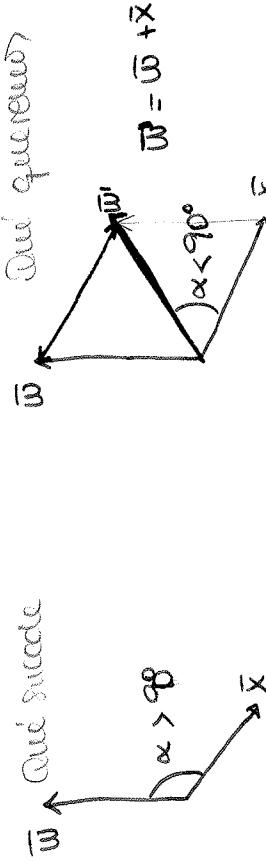
* Percepción de Rosenblatt — PERCEPCIÓN SIMBOL —

$$y = (x_1 \dots x_n) = \Theta(w_0 x_0 + w_1 x_1 + \dots + w_n x_n) = \Theta(\bar{w}^T \bar{x})$$

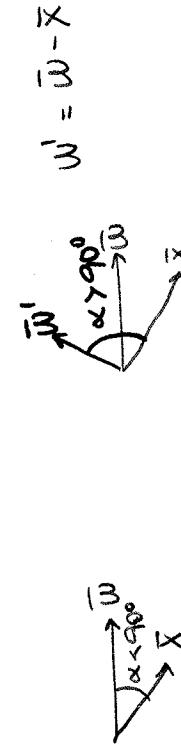
* Percepción de Rosenblatt para el perceptrón de Rosenblatt

$$\cdot \text{ si } y(\bar{x}) = 1 \quad y \quad \bar{x} \in C_1 \quad (t=1)$$

que sucede



$$\text{si } y(\bar{x}) = 1 \quad y \quad \bar{x} \in C_2 \quad (t=0)$$



* ALGORITMO

- Generar los pesos aleatoriamente
- Para cada ejemplo \bar{x}
calcular $y(\bar{x}) = \begin{cases} 1 & \text{si } \bar{w}^T \bar{x} > 0 \\ 0 & \text{si } \bar{w}^T \bar{x} < 0 \end{cases}$

- si $y(\bar{x}) = 0 \quad y \quad \bar{x} \in C_1 \rightarrow \bar{w} = \bar{w} + \eta \bar{x}$
- si $y(\bar{x}) = 1 \quad y \quad \bar{x} \in C_2 \rightarrow \bar{w} = \bar{w} - \eta \bar{x}$

* Criterio de Rosenblatt

$$\underline{J(\bar{w})} = \sum_{x \in D} d_x \bar{w}^T \bar{x}$$

Síne que
positivo

dónde $d_x = y(\bar{x}) - t(\bar{x})$

- si $y(\bar{x}) = 0$ y $t=1 \rightarrow d_x = -1 \rightarrow \sum_x \bar{w}^T \bar{x} \geq 0$
- si $y(\bar{x}) = 1$ y $t=0 \rightarrow d_x = 1 \rightarrow \sum_x \bar{w}^T \bar{x} > 0$

entonces minimizamos J con respecto a \bar{w}

$$\frac{\partial J(\bar{w})}{\partial \bar{w}} = \sum_{x \in D} d_x \bar{x} \Rightarrow \hat{\bar{w}} = \bar{w} - \eta \sum_x d_x \bar{x}$$

* ALGORITMO DE PERCEPCIÓN DE ROSENBLATT (η , dato d)

\bar{w} = pesos aleatorios $\in (-0^{15}, 0^{15})$
mientras haya errores de clasificación

para cada ejemplo $x \in D$ es un vector no un vector

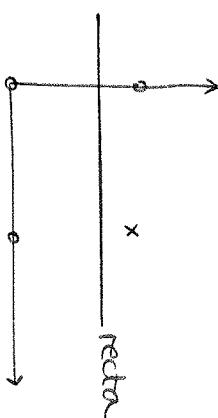
calculando $d_x = y(\bar{x}) - t(\bar{x})$

actualizamos: $\bar{w} = \bar{w} - \eta d_x \bar{x}$
pesos de \bar{w}

* EJEMPLO (AND) * enunciado

$$\eta = 0'25 \quad \bar{w} = (-0'3, 0'1, 0'4)$$

x_0	x_1	x_2	t
1	0	0	0
1	0	1	0
1	1	0	0
1	1	1	1



$$\underline{q1} \quad \bar{x} = (1 \ 0 \ 0)$$

$$S_x = y(\bar{x}) - t(\bar{x}) = 0$$

$(-0'3, 0, 0'4) - (0, 0, 0) = (-0'3, 0, 0'4)$ La recta no cambia porque no hay error de clasificación

$$\underline{q2} \quad \bar{x} = (1 \ 0 \ 1)$$

$$S_x = y(\bar{x}) - t(\bar{x}) = 1$$

\hookrightarrow ~~WTF~~

$$\begin{pmatrix} -0'3 \\ 0 \\ 0'4 \end{pmatrix} (1 \ 0 \ 1) = -0'3 + 0 + 0'4 = 0'1 \Rightarrow 1$$

$$y(\bar{x}) = 1$$

$$\bar{w} = (0'3, 0, 0'4) - 0'25 \cdot 1 (1, 0, 1) = (0'155, 0, 0'15)$$

$\bar{w} = (0'3, 0, 0'4) - 0'25 \cdot 1 (1, 0, 1) = (0'155, 0, 0'15)$ La recta no cambia porque no hay error de clasificación.

$$\underline{q3}$$

$$\bar{x} = (1, 1, 1)$$

$$S_x = y(\bar{x}) - t(\bar{x}) = -1$$

\hookrightarrow

$$\begin{pmatrix} -0'55 \\ 0 \\ 0'15 \end{pmatrix} (1, 1, 1) = -0'55 + 0'15 < 0$$

$$y(\bar{x}) = 0$$

$$\bar{w} = (0'55, 0, 0'15) - 0'25 (-1) (1, 1, 1) = \overbrace{(0'20, 0'25, 0'40)}^{\text{positivo}}$$

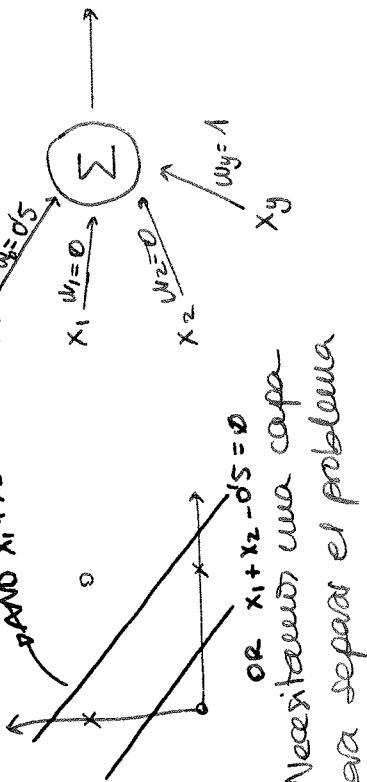
recta: $x_1 = 0 \rightarrow x_2 = 3/4$
 $x_2 = 0 \rightarrow x_1 = 1/4$

EJEMPLO XOR

$$(x_1 - x_2)^2$$

	x_1	x_2	t
0	1	0	0
1	1	0	1
1	1	1	0
0	1	1	0

$$x_1 + x_2 - 1'5 = 0$$



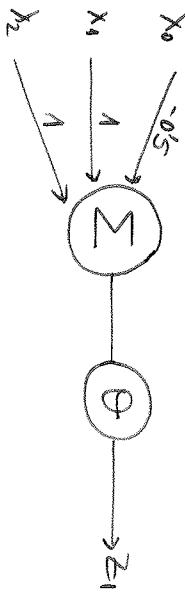
o2 $x_1 + x_2 - 0'5 = 0$

Necesitaremos una capa para separar el problema

Están rectas son las fronteras de los siguientes percepciones:

$$z_1 = \Theta(1(x_1 + x_2 - 0'5))$$

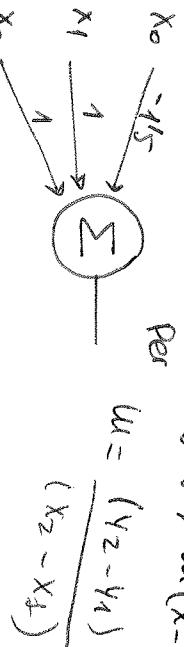
Percepcion



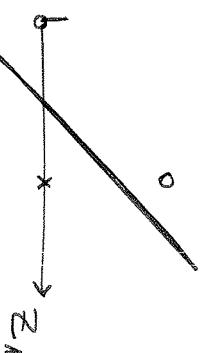
$$z_2 = \Theta(x_1 + x_2 - 1'5)$$

$$\text{Recta por los puntos}$$

$$(y - y_0) = u(x - x_0)$$



rectas

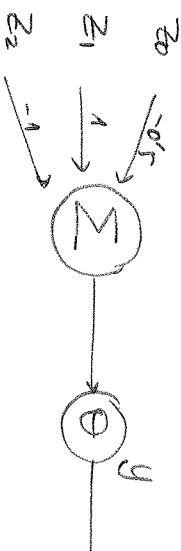


$$w_0 = -0'5$$

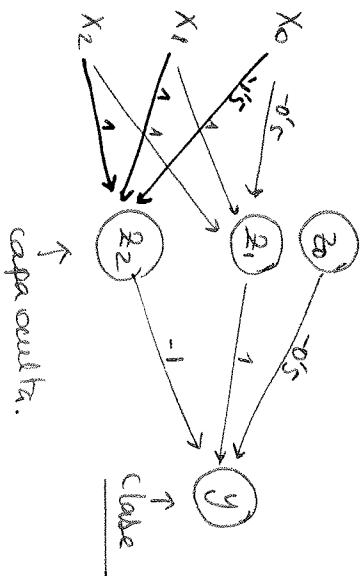
$$w_1 = 1$$

$$w_2 = -1$$

→ $y = \Theta(z_1 - z_2 - 0'5)$ Ahora el problema es separable linealmente.



Todo esto da lugar al perceptron multicapa.



↑ capa oculta.

* Regla delta

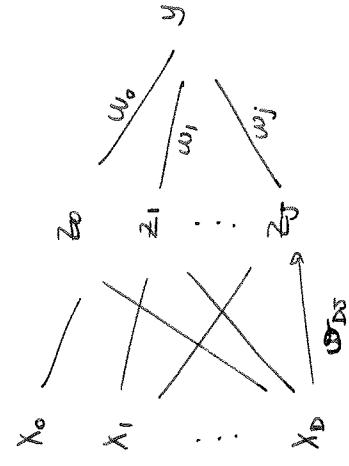
- Sustituimos Θ por σ , es decir, signos da en vez de escalón.
- Para perceptor de una capa esto equivale a reg. logística.

D: dimensión del problema

Σ : nº neuronas en la capa oculta

σ_{ds} : peso entre neurona D de entrada y la neurona J (oculta)

w_{ij} : peso entre neurona j (oculta) y salida.



con una red:

$$n^{\text{º}} \text{ parámetros} = (D+1) \times J + J + 1$$

$$\bar{x} = (x_0, x_1, \dots, x_D) \quad \bar{z} = (z_0, z_1, \dots, z_J)$$

$$z_0 = 1$$

$$x_0 = 1$$

Salida de la red:

$$y(\bar{x}) = \sigma \left(\bar{w}^T \bar{z} \right) = \sigma \left(\sum_{j=0}^J w_j z_j \right) = \sigma \left(\sum_{j=0}^J w_j \sigma \left(\sum_{d=0}^D x_d \sigma_{\text{ds}} \right) \right)$$

$$\text{matriz } V = \begin{pmatrix} v_{00} & \cdots & v_{0J} \\ \vdots & \ddots & \vdots \\ v_{D0} & \cdots & v_{DJ} \end{pmatrix}$$

$$z_j = \sigma \left(\sum_{d=0}^D x_d \sigma_{\text{ds}} \right)$$

$$D = t_1, \dots, t_N \quad | \quad t_i, 1 \text{ si } \bar{x}_i \in C_1$$

$$I = \bar{x}_1, \dots, \bar{x}_N \quad | \quad t_i, 0 \text{ si } \bar{x}_i \in C_2$$

$$y(\bar{x}) = P(c_1 | \bar{x}, V, \bar{w})$$

$$\begin{aligned} \text{* Resolvemos por ML:} \\ P(c_1, \dots, c_N | \bar{x}_1, \dots, \bar{x}_N) &= \prod_{n=1}^N P(c_n | \bar{x}_n, V, \bar{w}) \\ &= (1 - P(c_1 | \bar{x}_1, V, \bar{w}))^{1-t_1} \cdot \\ &\quad \cdot (P(c_1 | \bar{x}_1, V, \bar{w}))^{t_1} \end{aligned}$$

$$= \prod_{n=1}^N y(\bar{x}_n)^{t_n} (1-y(\bar{x}_n))^{1-t_n}$$

Aplicando -ln

$$E(v, \bar{w}) = -\ln p(t_1, \dots, t_N | \bar{x}_1, \dots, \bar{x}_N, v, \bar{w}) = \sum_{n=0}^N E_n(v, \bar{w})$$

$$E_n(v, \bar{w}) = -t_n \ln y(\bar{x}_n) - (1-t_n) \ln (1-y(\bar{x}_n))$$

— Derivada conodín —

$$\begin{aligned} \frac{\partial t_n}{\partial \beta} &= -t_n \frac{1}{y(\bar{x}_n)} \cdot \frac{\partial y(\bar{x}_n)}{\partial \beta} + (1-t_n) \frac{1}{1-y(\bar{x}_n)} \cdot \frac{\partial y(\bar{x}_n)}{\partial \beta} = \\ &= -t_n (1-y(\bar{x}_n)) \frac{\partial \bar{w}^{\top} \bar{z}}{\partial \beta} + (1-t_n) y(\bar{x}_n) \frac{\partial \bar{w}^{\top} \bar{z}}{\partial \beta} = \end{aligned}$$

$$= (y(\bar{x}_n) - t_n) \frac{\partial \bar{w}^{\top} \bar{z}}{\partial \beta}$$

$$\frac{\partial y(\bar{x}_n)}{\partial \beta} = \frac{\partial}{\partial \beta} \frac{1}{1 + e^{-\bar{w}^{\top} \bar{z}}} = y(\bar{x}_n) (1-y(\bar{x}_n)) \frac{\partial \bar{w}^{\top} \bar{z}}{\partial \beta}$$

Optimizamos respecto a w_i ($\beta \rightarrow w_i$)

$$\frac{\partial \bar{w}^{\top} \bar{z}}{\partial w_i} = z_i \stackrel{\text{desarrollo}}{=} \frac{\partial}{\partial w_i} ((w_0 z_0 + w_1 z_1 + \dots + w_j z_j) = z_j$$

$$\Rightarrow \frac{\partial t_n}{\partial w_i} = (y(\bar{x}) - t_n) z_i$$

Optimizamos respecto a v_{pq} ($\beta \rightarrow v_{pq}$)

$$\frac{\partial \bar{w}^{\top} \bar{z}}{\partial v_{pq}} = \frac{\partial}{\partial v_{pq}} \sum_{j=0}^J \bar{w}_j \bar{z}_j = \sum_{j=0}^J w_j \frac{\partial}{\partial v_{pq}} \left(\sum_{d=0}^D x_d v_{pd} \right) =$$

$$= \sum_{j=0}^J w_j z_j (1-z_j) \sum_{d=0}^D x_d \frac{\partial v_{pd}}{\partial v_{pq}} = \sum_{j=0}^J w_j z_j (1-z_j) \sum_{d=0}^D \delta_{pd} \delta_{dq} =$$

$$d_{ij} = h^A \delta_{ij} \delta_{i=j}$$

$$\left[\frac{\partial \sigma_a}{\partial \sigma_q} = \left(y(\bar{x}_u) - t_u \right) \frac{\partial \bar{w}^T \bar{z}}{\partial \sigma_q} = \left(y(\bar{x}) - t_u \right) w^T z_f (1 - \bar{z}_f) x_f \right]$$

* Reglas de actualización

$$w_i \leftarrow w_i - \eta (y(\bar{x}_u) - t_u) z_i$$

$$v_{pq} \leftarrow v_{pq} - \eta (y(\bar{x}_u) - t_u) w_q z_q (1 - z_q) x_p$$

ALGORITMO BATCH PROPAGATION - 2 CLASES (η , epochs, Dmax)

inicializamos v, \bar{w} a valores entre [0.05, 0.5]

for ie = 1 → epochs

for u = 1 → N

$$\bar{z}_q = \sigma \left(\sum_{d=0}^D v_{dq} \cdot \bar{x}_d \right) \quad // \quad q = 1 \rightarrow J$$

$$y(\bar{x}_u) = \sigma(\bar{w}^\top \cdot \bar{z})$$

$$\delta_u = y(\bar{x}_u) - t_u$$

$$\Delta_q = \delta_u w_q \bar{z}_q (1 - \bar{z}_q) \quad // \quad q = 1 \rightarrow J$$

Actualización → $w_q = w_q - \eta \delta_u \bar{z}_q \quad // \quad q = 1 \rightarrow J$

$$\rightarrow v_{pq} = v_{pq} - \eta \Delta_q x_p \quad // \quad p = 1 \rightarrow D$$

MLP para problemas multiclas (varias salidas y)

k = # clases

$J = n^2$ de neuronas en capa oculta

$D = n^2$ attr.

$v_{ij} =$ peso entre neurona i (entrada) y j (oculta)

$w_{ik} =$ peso entre neurona j (oculta) y k (salida)

$y_{ik}(\bar{x}) =$ prob. de que $\bar{x} \in C_k$

$$y_k = P(C_k | V, W, \bar{x})$$

por teorema de Bayes

$$P(c_k | \bar{x}) = \frac{P(\bar{x} | c_k) P(c_k)}{\sum_{k=1}^K P(\bar{x} | c_k) P(c_k)} = \frac{\exp(a_k)}{\sum_{k=1}^K \exp(a_k)}$$

$$a_k = \ln P(\bar{x} | c_k) P(c_k)$$

Ahora separaremos que a_k es la integración y_k de las salidas de la capa oculta - esto es:

$$a_k = \sum_{j=1}^J z_j w_{kj}$$

$$\begin{aligned}y_k &= P(c_k | \bar{v}, \bar{w}, \bar{x}) = \frac{\exp(a_k)}{\sum_{k=1}^K \exp(a_k)} = \\&= \frac{\exp\left(\sum_{j=1}^J w_{kj} z_j\right)}{\sum_{k=1}^K \exp\left(\sum_{j=1}^J w_{kj} z_j\right)}\end{aligned}$$

Consideremos los datos

$D_{train} = (\bar{x}_1, \bar{v}_1, \bar{y}_1, \dots, \bar{x}_N, \bar{v}_N, \bar{y}_N)$. Aquí \bar{v}_n es un vector de lado \emptyset excepto en la posición de la clase.

$$\text{Si } \bar{x} \in C_k \rightarrow \begin{cases} t_{kk} = 1 \\ t_{ij} = 0 \quad \forall j \neq k \end{cases}$$

Maximizando por MV (MU)

$$\begin{aligned}P(D | H, I) &= P(E_1, \dots, E_N | \bar{v}_1, \bar{w}_1, \bar{x}_1, \dots, \bar{x}_N) = \\&= \prod_{n=1}^N P(E_n | \bar{v}_n, \bar{w}_n, \bar{x}_n) = \prod_{n=1}^N \prod_{k=1}^K t_{nk} y_{nk} \\P(E_n | \bar{v}_n, \bar{w}_n) &= \prod_{k=1}^K y_{nk}^{t_{nk}}\end{aligned}$$

- ... Aplicaremos - en
 $E(v, w) = -\ln P(E_1, \dots, E_N | \bar{v}, \bar{w}, \bar{x}) = -\sum_{n=1}^N \sum_{k=1}^K t_{nk} \ln y_{nk}$
... calcularámos un término
 $E_n(v, w) = \sum_{k=1}^K t_{nk} \ln y_{nk}$

Derivada conoedita

$$\frac{\partial t_n}{\partial \beta} = - \sum_{k=1}^K t_{nk} \frac{1}{y_{nk}} \frac{\partial y_{nk}}{\partial \beta} = - \sum_{k=1}^K t_{nk} \left(\frac{\partial a_{nk}}{\partial \beta} \sum_{r} y_{nr} \frac{\partial a_{nr}}{\partial \beta} \right)$$

derivada softmax

$$\beta = w_{qr}$$

$$\frac{\partial a_{nk}}{\partial \beta} = y_{nk} \left(\frac{\partial a_{nk}}{\partial \beta} - \sum_r y_{nr} \frac{\partial a_{nr}}{\partial \beta} \right)$$

$$\frac{\partial a_{nk}}{\partial w_{qr}} = \sum_{j=1}^K (y_{nj} - t_{nj}) \frac{\sum_{i=1}^K z_{ij} w_{ij}}{\sum_{r} y_{nr}} =$$

$$= \sum_k \sum_j (y_{nk} - t_{nk}) z_{kj} \sum_r w_{jr} = (y_{nk} - t_{nk}) z_{qk} \quad (1)$$

$$\beta = w_{pq}$$

$$\frac{\partial a_{nk}}{\partial w_{pq}} = \sum_k (y_{nk} - t_{nk}) \frac{\partial a_{nk}}{\partial w_{pq}} = \sum_k (y_{nk} - t_{nk}) \sum_j w_{jk} z_{j'}$$

$$\cdot (1 - z_{j'}) \sum_i x_{ni} \delta_{ip} \delta_{jq} =$$

$$= \sum_{k=1}^K (y_{nk} - t_{nk}) w_{pq} z_{qk} (1 - z_{qk}) \bar{x}_{np}$$

Bach propagation nc (y , epochs, Dtrain)

Inicializamos o_j con valores entre $[0.5, 0.5]$

for $i = 1 \rightarrow N$

for $n = 1 \rightarrow N$

Calculamos la red:

$$z_j = \sigma\left(\sum_i x_{ni} o_{ij}\right) \quad // \sigma * D$$

$$a_k = \sum_{j=0}^J z_j w_{jk} \quad // D * K$$

$$y_k = \exp(a_k) / \sum_{k=1}^K \exp(a_k) \quad // K$$

Para cada col. de salida $A \rightarrow k$

$$\Delta_k = y_k - b_{nk}$$

Para cada neurona oculta $A \rightarrow \bar{J}$

$$\Delta_j = \sum_{k=1}^K \Delta_k w_{kj} (1 - z_j)$$

actualizamos

$$w_{jk} = w_{jk} - \eta \Delta_k z_j$$

~~$$w_{ij} = w_{ij} - \eta \Delta_j x_{ni}$$~~

ret w, b

ALGORITMOS GENÉTICOS

Darwin

- Población de individuos compartiendo recursos.

• El mecanismo de adaptación al entorno

• Reproducción

• Mutación

• Individuos que mejor se adaptan sobreviven.

AG utiliza estos ideas para resolver problemas de optimización

• Problema (entorno)

- Función de fitness (mide cómo se adapta un individuo)

• Conjunto de soluciones (Población)

• Individuos codifican una solución

- Individuos con mayor fitness mayor prob. de reproducción.

• Los individuos se recombinan heredando parte del material genético de sus progenitores

• Hay mutaciones aleatorias.

Antes de empezar hay que concretar:

- Codificación de la solución en una cadena (cromosoma

- Tamaño población.

- Definir operadores de la evolución:

- Selección progenitores

- Recombinación

- Mutación

- Selección supervivientes

- Condición terminación

ag (fitness f , parámetros de evolución)

P = crear-población-alatoria (tamaño)

while (no se cumple criterio de terminación)

P' = selección-progenitores (P)

P' = recombinación (P')

P' = mutación (P')

P = selección-superiores (P, P')

end

return best (P)

f

Ej: encontrar el valor máximo de $f(x) = x^2$ en [0, 34]

con x entero.

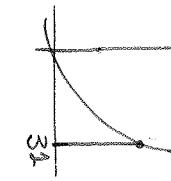
cromosoma: cadenas de 5 bits.

b ₁	b ₂	b ₃	b ₄	b ₅
----------------	----------------	----------------	----------------	----------------

$$x = \sum_{i=1}^5 b_i 2^{5-i}$$

Tamaño: T=4

Población: b puede valer 0 ó 1 .



- selección progenitores: aleatoria y proporcional a fitness.
- (ruleta con pesos):

Individuo	f
Individuo 1	100
Individuo 2	25
Individuo 3	50

- Recombinación: cruce entre P¹⁰.

0	1	0	1	0	1
1	1	0	1	0	0

→

0	1	1	0	1	0
1	1	1	0	1	1

- Mutación: cambio de bit con prob. P_m (pequeña)

$$\text{ejm: } P_m = \frac{1}{20} \rightarrow r = 4 * b = 5 = 20$$

Selección & Reproducción: sustitución

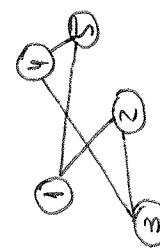
PROB. INICIAL	X	FITNESS	$f_i / \sum f_i$	$\frac{N}{2}$ esperado	núm. select
0 1101	B	169	0'14	0'58	1
11000	24	576	0'49	1'97	2
01000	8	64	0'06	0'22	0
10011	19	361	0'34	1'23	1
					$f = 293$

SELECCIÓN	PEOS	P. COCE	MUTOS	X	f_i	MUTACIÓN	X	f_i
0 1101			0 1100	12	144	01100		
1 1000			1 1001	25	625	11001		
11000			11011	27	729	11011		
10011			10000	16	256	10000	20	400
							$f = 439$	La mutación

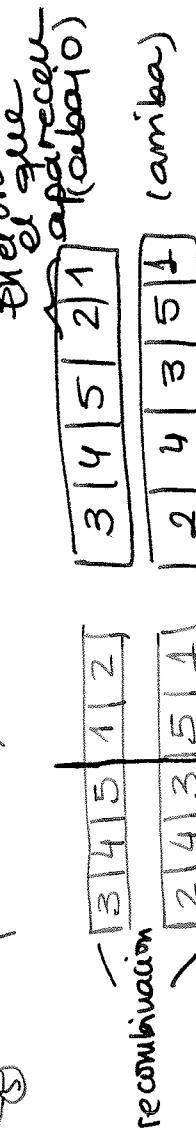
Prob del viajante

3	4	5	1	2
---	---	---	---	---

permutación



fitness = 1/distancia



mutación: cambiar 2 n^o.

2	4	3	5	1
2	1	3	5	4

Optimización pesos del perceptrón multicapa

PESOS	v_{01}	v_{02}	...	v_{0j}	w_{01}	w_{02}	...	w_{0k}
-------	----------	----------	-----	----------	----------	----------	-----	----------

$$fit = \frac{1}{\text{error} + 0.005}$$

fit2 = precisión.

Mutación: Añadir ruido gaussiano $\approx N(0, 1)$

Algoritmo

* TEORÍA DE ESQUEMAS
Un bloque o esquema es una cadena (parcodificación binaria) compuesta de: 0, 1 y * no definido

$H = 1 * * * 0$ Todas las cadenas empiezan por 1 y terminan por 0.

$O(H)$: Orden del esquema H . No se bits definidos

$\delta(H)$ = longitud del esquema. Distancia entre dos bits definidos más lejanos.

$$e_i: H = * 1 0 * 0 \quad \delta(H) = 3.$$

Para cadenas de longitud L , tendremos 2^L cromosomas posibles; $(2+1)^L$ esquemas.

Una cromosoma es instancia de 2^L esquemas

$$e_i: 101 \Rightarrow$$
 está en 2^3 esquemas

101	10*	*01	***
1*1	*	0*	
1**	*	**1	

Una población de N cromosomas representa $O(N^2)$ cromosomas.

Inicialmente tendremos:

$$N/2 \quad 1 * * * \dots$$

$$N/2 \quad 0 * * * \dots$$

$n_H(t)$: nº de instancias de H en tiempo t .

$f_i(t)$: fitness individuo i en tiempo t .

$\bar{f}(t)$: fitness medio población en tiempo t .

$\bar{f}_H(t)$: fitness medio H en tiempo t .
de las instancias que cumplen

$\langle n_H(t+1) \rangle = N^2$ esperado en tiempo $t+1$ de instancias
de H .

Selección de progenitores proporcional a fitness

$$\text{fitness: } \frac{f_i(t)}{\sum_{i=1}^N f_i(t)}$$

$$\langle n_i(t+1) \rangle = N \frac{f_i(t)}{\sum f_i(t)} = \frac{f_i(t)}{\bar{f}(t)}$$

\hookrightarrow media

$$\langle n_H(t+1) \rangle = N \frac{\sum f_i(t)}{\sum_{i=1}^N f_i(t)} = \frac{n_H(t) \bar{f}_H(t)}{\bar{f}(t)}$$

$$\bar{f}_H(t) = \frac{1}{n_H(t)} \sum_{i \in H} f_i(t)$$

Si $\bar{f}_H(t) > \bar{f}(t) \Rightarrow$ más probable que $n_H(t+1) > n_H(t)$

Añadimos cruce (cruce en un punto)

$$q_1: \begin{array}{|c|} \hline 0 & 1 & 1 & 1 & 0 \\ \hline 1 & 0 & 1 & 0 & 1 \\ \hline \end{array} \Rightarrow \begin{array}{l} 11110 \\ 00101 \end{array}$$

$\boxed{* 1 *** 0}$

$$S_c(H) = 1 - \frac{s(H)}{l-1}$$

Prob. de que sobreviva el esquema al cruce.

→ mutación

p_m = prob. de mutación

Prob. mutación = $1 - p_m$
de un bit

P supervivencia = $(1 - p_m)^{O(H)}$ → n° de bits activos o definidos
en el esquema.

$$\langle n_H(t+1) \rangle \geq \frac{\bar{f}_H(t)}{\bar{f}(t)} n_H(t) \left(1 - p_c \frac{s(H)}{l-1} \right) (1 - p_m)^{O(H)}$$

↳ prob. de cruce: u DIC 2013

Ejemplo

$$f(x) = x^2$$

$$\text{fitness} = \sum_{i=1}^5 (b_i 2^i)^2$$

Prob. inicial

	X	t
0 1 1 0 1	13	169
1 1 0 0 0	24	576
0 1 0 0 0	8	64
1 0 0 1 1	19	361

$$\bar{f}_H(t) = \frac{576 + 361}{2} = 468.5$$

$$P_{SOE}(H) = \frac{576 + 361}{2} \cdot \frac{1}{293} \cdot 2 = 32$$

$$p_m = 1/20$$

$$s_c(H) = \left(1 - \frac{s(H)}{l-1} \right) = 4$$

$$S_m(H) = (1 - p_m)^{O(H)} = 19/20$$

$$\langle n_H(t+1) \rangle \sim S_m(H) s_c(H) \cdot S_m(H-1) \dots$$

$$H_2 = *10*** \quad f_{H_2} = \frac{576 + 64}{2} = 320 \quad \# \text{cuando los bits estan en los extremos } S_C = \emptyset$$

$$S_S(H_2) = \frac{576 + 64}{2} \cdot \frac{1}{293} \cdot 2 = \underline{218}$$

$$S_C(H_2) = \left(1 - \frac{d(H_2)}{e-1}\right) = \left(1 - \frac{1}{5-1}\right) = \underline{0'75}$$

$$S_H(H_2) = (1 - p_m)^{f(H_2)} = (19/20)^2$$

$\Downarrow \# \text{ de bits que fueron definidos.}$

$$\langle n_{H_2}(t+1) \rangle \geq 2^95$$

$$H_3 = 1 *** 0$$

$$S_S(H_2) = \underline{1'96}$$

$$\langle n_{H_2}(t+1) \rangle \geq 0$$

$$S_C(H_2) = \emptyset$$

$$S_H(H_2) = (19/20)^2$$

Example 3 # Encrucijade.

cadena	fit
10001	20
11100	10
00011	5
01110	15

$$P_m = 0'01 \quad f = 125$$

$$p_c = 0'9$$

$$H_1 = 1 * + * *$$

$$H_2 = 0 * + 1 *$$

$$? n_{H_1}(t+1) \text{ y } n_{H_2}(t+1) ?$$

$$S_H(H_1) = (1 - 0'9) \frac{15}{4} = 1$$

$$S_H(H_2) = (1 - 0'9) \frac{10}{2} = 0'19$$

$$\langle n_{H_1}(t+1) \rangle > \underline{\underline{2^{376}}}$$

$$H_2 \quad f_{H_2}(t) = \frac{5+15}{2} = 10$$

$$S_S(H_2) = \frac{10}{125} \cdot 2 = 1'6$$

$$S_C(H_2) = 1 - 0'9 \frac{3}{4} = 0'075 \quad \langle n_{H_2}(t+1) \rangle > \underline{\underline{1'176}}$$

$$S_H(H_2) = 0'99^2 = 0'98$$

$$H_1 \quad f_{H_1}(t) = \frac{20 + 10}{2} = 15$$

$$S_S(H_1) = \frac{15}{125} \cdot 2 = 2'4$$

$$S_C(H_1) = (1 - 0'9) \frac{10}{4} = 1$$

$$\langle n_{H_1}(t+1) \rangle = 0'199$$

CLUSTERING (agrupamiento)

Para agrupar necesitaremos:

- * Atributos
- * Medida de proximidad o similitud.
- * Algoritmo de clustering.
- * Validación e interpretación de resultados

Definición de clustering

$X = \{x_i\}_{i=1, \dots, N}$ definimos m-clustering como una partición en m subconjuntos C_1, C_2, \dots, C_m tal que ningún grupo esté vacío y $c_i \cap c_j = \emptyset \forall i \neq j$.

Medidas de proximidad

Sean \bar{x} y $\bar{x}' \in X$ la métrica de distancia d ha de cumplir:

- * $0 \leq d(\bar{x}, \bar{x}') \leq \infty$
- * $d(\bar{x}, \bar{x}') = 0 \Leftrightarrow \bar{x} = \bar{x}'$
- * $d(\bar{x}, \bar{x}') = d(\bar{x}', \bar{x})$
- * $d(\bar{x}, \bar{x}'') \leq d(\bar{x}, \bar{x}') + d(\bar{x}', \bar{x}'')$

Distancias entre puntos

$$\text{Euclídea } d(\bar{x}, \bar{x}') = \sqrt{\sum_{d=1}^D (x_d - x'_d)^2}$$

$$l_1 \circ \text{Manhattan } d(\bar{x}, \bar{x}') = \sum_{d=1}^D |x_d - x'_d|$$

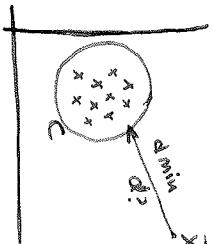
Distancia entre un punto y un cluster.

- Minimo

$$d(\bar{x}, c) = \min_{\bar{x}' \in c} (\bar{x}, \bar{x}')$$

- Máximo

$$d(\bar{x}, c) = \max_{\bar{x}' \in c} (\bar{x}, \bar{x}')$$

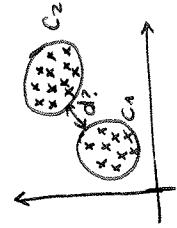


- Media

$$d(\bar{x}, c) = \frac{1}{n} \sum_{\bar{x}' \in c} (\bar{x}, \bar{x}')$$

Distancia entre clusters

- Número (enlace simple)



$$d_{\min}(c_1, c_2) = \min_{\bar{x} \in c_1, x' \in c_2} d(\bar{x}, x')$$

- Máximo (enlace completo)

$$d_{\max}(c_1, c_2) = \max_{\bar{x} \in c_1, \bar{x}' \in c_2} d(\bar{x}, \bar{x}')$$

- Media

$$d_{\text{med}}(c_1, c_2) = \frac{1}{|c_1||c_2|} \sum_{\bar{x} \in c_1, \bar{x}' \in c_2} d(\bar{x}, \bar{x}')$$

Clustering jerárquico aglomerativo.

Darle una secuencia de agrupamientos

$$R_0 \subset R_1 \subset R_2 \subset \dots \subset R_{N-1}$$

tal que $R_0 = \{c_i = \{\bar{x}_i\} | i = 1, \dots, N\}$ // cada punto es un cluster:

y $R_{N-1} = \{c_1 = \{\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n\}\}$ // todos los puntos en 1 cluster.

ALGORITMO

clus-jer-aglo ($x = \{\bar{x}_1, \dots, \bar{x}_n\}$, métrica d)

inicializar $R_0 = \{c_i = \{\bar{x}_i\} | i = 1, \dots, N\}$

$\eta = \emptyset$;

do

$\eta = \eta + 1$;

 Buscar clusters c_i, c_j tal que $d(c_i, c_j)$ sea mínima;

$$R_\eta = \{R_{\eta-1} - c_i - c_j\} \cup \{c_i \cup c_j\}$$

 hasta que no haya un cluster.

return R_0, \dots, R_{N-1}

Resulta útil definir una matriz de distancias \Rightarrow tal que

Dij sea $d(c_i, c_j)$

$$P_4: \bar{x}_1 \bar{x}_2 \bar{x}_3 \bar{x}_4 \bar{x}_5$$

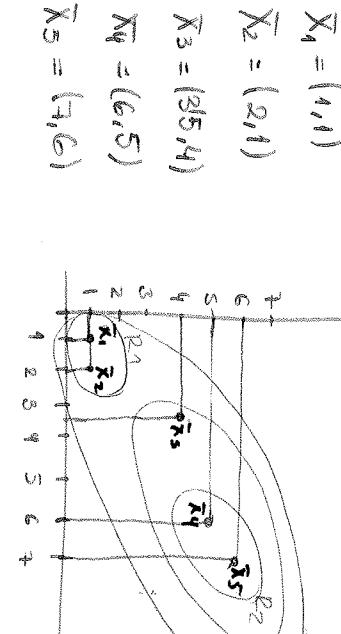
$$\bar{x}_1 = (1,1)$$

$$\bar{x}_2 = (2,1)$$

$$\bar{x}_3 = (3,5,4)$$

$$\bar{x}_4 = (6,5)$$

$$\bar{x}_5 = (4,6)$$



$$R_0 = \{ \bar{x}_1, \bar{x}_2, \bar{x}_3, \bar{x}_4, \bar{x}_5 \}$$

d = distancia (euclidean simple) con distancia euclídea.

$n=1$

$$R_1 = \{ \bar{x}_1, \bar{x}_2, \bar{x}_3, \bar{x}_4, \bar{x}_5 \}$$

$n=2$

$$R_2 = \{ \bar{x}_1, \bar{x}_2, \bar{x}_3, \bar{x}_4, \bar{x}_5 \}$$

Actualizaremos la matriz

$$D = \begin{pmatrix} 0 & 3'4 & 0 \\ 3'4 & 0 & 2'7 \\ 2'7 & 0 & 0 \end{pmatrix}$$

$$D = \begin{pmatrix} 0 & 3'4 & 0 \\ 3'4 & 0 & 2'7 \\ 2'7 & 0 & 0 \end{pmatrix}$$

\dots

$$R_3 = \{ \bar{x}_1, \bar{x}_2, \bar{x}_3, \bar{x}_4, \bar{x}_5 \}$$

$n=3$

$$\{ \bar{x}_1, \bar{x}_2, \bar{x}_3, \bar{x}_4, \bar{x}_5 \}$$

$$R_4 = \{ \bar{x}_1, \bar{x}_2, \bar{x}_3, \bar{x}_4, \bar{x}_5 \}$$

$$D = \begin{pmatrix} 0 & 3'4 & 0 \\ 3'4 & 0 & 0 \end{pmatrix}$$

* Orden de ejecución

N puntos

$(N-1)$ pasos y en cada paso juntamos dos en el paso n

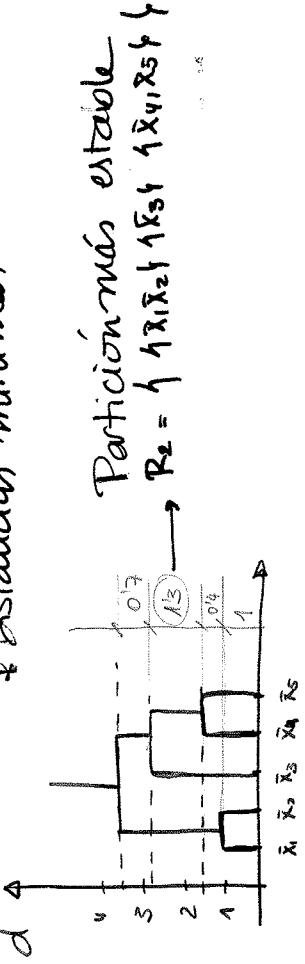
hay $N-n$ grupos.

$$\frac{N(N-1)}{2} + \frac{(N-1)(N-2)}{2} + \dots + \frac{2 \cdot 1}{2} = O(N^3)$$

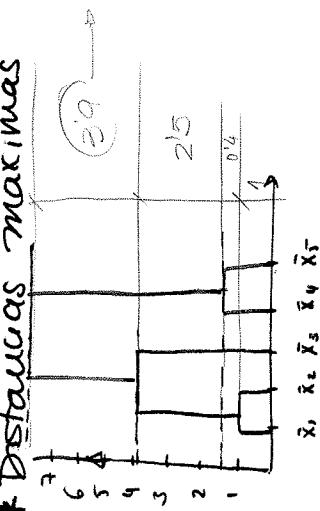
$\boxed{N - 2 \text{ términos}}$

Dendogramas

* Distancias mínimas



* Distancias máximas



Clustering secuencial

Se procesan los puntos secuencialmente. Cada punto se asigna a un cluster o se crea un cluster nuevo.

Se usa distancia euclídea.

clust-sec ($X = \{\bar{x}_1, \dots, \bar{x}_n\}$, métrica d, umbral θ)

$$c_1 = \{\bar{x}_1\}$$

$$w = 1$$

para cada patrón \bar{x}_i con $i = 2 \dots n$

Busca el cluster C_k tal que $d(\bar{x}_i, c_k) =$

$\min d(\bar{x}_i, c_k) \leq w$

si $d(\bar{x}_i, c_k) \leq \theta$
 $C_k = c_k \cup \bar{x}_i$

else

$w = w + 1$
 $c_w = \bar{x}_i$

$$E_1 : \left[\begin{array}{c} \{x_1, x_2, x_3, x_4, x_5\} \\ D = \begin{pmatrix} 0 & x_2 \\ 1 & 0 \\ 3^1 9 & 3^4 0 \\ 6^1 4 & 5^1 7 & 2^1 7 & 0 \\ 7^1 8 & 7^1 4 & 4^1 0 & 1^1 4 & 0 \end{pmatrix} \\ \Theta = 3 \\ d = \text{dmin} \end{array} \right] \text{enunciado}$$

$$\begin{aligned} w &= 1 & \bar{x}_2 \\ c_1 &= \{x_1\} & d(\bar{x}_1, c_1) = 1 \leq \Theta \\ c_1 &= \{x_1, x_2\} & c_1 = \{x_1, x_2\} \\ d(\bar{x}_4, c_1) &= 5^1 7 & \bar{x}_3 \\ d(\bar{x}_1, c_2) &= 2^1 7 & d(\bar{x}_3, c_1) = 3^1 4 > \Theta \\ \text{cogiendo el} & & w = 2 \\ \text{mínimo y aplicando} & & c_1 = \{x_1, x_2\} \quad c_2 = \{x_3\} \\ \text{el criterio} & & \end{aligned}$$

$$\bar{x}_4 \\ d(\bar{x}_4, c_1) = 5^1 7 \\ 2^1 7 \leq \Theta$$

$$c_1 = \{x_1, x_2\} \\ c_2 = \{x_3, x_4\}.$$

d(\bar{x}_4, c_1) = 5¹ 7
cogiendo el mínimo y aplicando el criterio

Solución

$$c_1 = \{x_1, x_2\}$$

$$c_2 = \{x_3, x_4, x_5\}$$

$$w = 2$$

$$r_{\min}$$

D: clustering languages

enunc. [solo con ESP, FRA, HUN, ING, ITA, NOR $\Theta = 4$]

$$\boxed{1^o} \quad C_1 = \{ESP\} \quad \boxed{2^o} \quad d(ESP, c_1) = 2 \leq \Theta \\ w = 1 \quad c_1 = \{ESP, FRA\}$$

$$d(HUN, c_1) = 10 > \Theta$$

$$\boxed{3^o} \quad d(HUN, c_1) = 10 > \Theta$$

$$C_1 = \{ESP, FRA\} \\ C_2 = \{HUN\}$$

$$C_3 = \{ING\}$$

$$\boxed{50} \quad d(\text{ITA}) = 1 \leq \theta \quad d(\text{ITA}, c_2) = 10 \\ \min \quad d(\text{ITA}, c_3) = 6$$

$$c_1 = \text{HUN, FRA, ITA} \quad c_2 = \text{HUN} \quad c_3 = \text{ING}$$

$$\boxed{50} \quad d(\text{NOE}, c_1) = 6 \quad d(\text{NOE}, c_2) = 8 \quad d(\text{NOE}, c_3) = 2 \leq \theta$$

Solución $c_1 = \text{ESP, FRA, ITA}$

$$\boxed{m=3} \quad c_2 = \text{HUN} \quad c_3 = \text{ING, NOE}$$

af) Tercería con dueño

